

Interopérabilité et orchestration agentiques : revue de la littérature académique

André-Guy Bruneau · agbruneau@gmail.com · 9 août 2026

Résumé Cette revue examine la littérature académique sur l’interopérabilité et l’orchestration des agents fondés sur les grands modèles de langue en entreprise, arrêtée au 9 août 2026. Elle prend pour corpus 161 pièces, dont 158 déposées sur arXiv, chacune ouverte sur sa notice et confrontée aux métadonnées canoniques du dépôt.

Le premier résultat tient à la forme du corpus, non à son contenu. **Douze pièces sur 158 — 8 % — portent une attestation de publication dans leur notice.** Vingt-six autres annoncent une acceptation dans le seul champ de commentaire libre, que personne ne vérifie. **Les 120 restantes, soit 76 %, ne présentent aucun signe de revue par les pairs.** Cinquante-huit pour cent du corpus a été déposé en 2026 et la moitié n’a jamais été révisée. *Un champ dont les trois quarts des énoncés n’ont franchi aucun comité ne peut pas fonder une décision d’architecture au même titre qu’une littérature établie, et cette revue le déclare avant d’en rapporter le contenu.*

Neuf fronts sont examinés — protocoles, sécurité, identité et délégation, systèmes multi-agents, évaluation, couche transactionnelle, processus d’affaires, gouvernance, Web agentique. Pour chacun, la revue distingue ce que la littérature établit, où elle se contredit réellement, et ce qu’elle ne traite pas. Trois désaccords méritent d’être nommés : la validité même des instruments qui mesurent le risque protocolaire, l’utilité du multi-agent comparé à l’agent unique, et le choix entre suspendre l’effet jusqu’à confirmation ou l’émettre et organiser sa révision.

La revue confronte enfin trois énoncés de la veille technologique du même auteur à ce que la littérature en dit. Deux en ressortent modifiés : le déficit de délégation au-delà de deux sauts est un déficit d’adoption et non d’invention, et la dissymétrie entre agents et formalismes de processus est industrielle, non scientifique. Le troisième — l’absence de vocabulaire de trace décrivant une chaîne de mandat — est confirmé par une seconde voie, plus sévère que la première.

Table des matières

1	Introduction	4
1.1	Question de revue	4
1.2	Rapport à la veille technologique	4
2	Méthode	4
2.1	Constitution du corpus	4
2.2	Régime de vérification	5
2.3	Ce que cette revue ne peut pas établir	6
3	Physionomie du corpus	6
3.1	Ce que la forme du corpus dit avant son contenu	6
3.2	Répartition par front et par régime de preuve	7
4	Les protocoles d'interopérabilité	8
4.1	Ce que la littérature établit	8
4.2	Le désaccord : prévalence mesurée ou prévalence héritée	9
4.3	Ce qu'elle ne traite pas	9
5	La sécurité des agents et de leurs protocoles	9
5.1	Ce que la littérature établit	9
5.2	Où elle se contredit	10
5.3	Ce qu'elle ne traite pas	10
6	L'identité, la délégation et la révocation	10
6.1	Ce que la littérature établit	10
6.2	Où elle se contredit	11
6.3	Ce qu'elle ne traite pas	12
7	Les systèmes multi-agents : orchestration et défaillance	12
7.1	Ce que la littérature établit	12
7.2	Où le désaccord est réel	13
7.3	Ce qui n'est pas traité	14
8	L'évaluation, les bancs d'essai et l'observabilité	14
8.1	Ce que la littérature établit	14
8.2	Où le désaccord est réel	14
8.3	Ce qui n'est pas traité	15
9	La couche transactionnelle : paiements, marchés, réputation	15
9.1	Ce que la littérature établit	15
9.2	Où le désaccord est réel	16
9.3	Régimes de preuve et lacunes	16
10	Les processus d'affaires et l'exécution durable	17
10.1	Ce qui est établi	17
10.2	Le désaccord dur : atomicité contre réversibilité	18
10.3	Ce que la littérature ne traite pas	18
11	La gouvernance, le risque et la responsabilité	19
11.1	Ce qui est établi	19
11.2	Deux désaccords, dont un de prémisses	19
11.3	Ce que la littérature ne traite pas	20
12	Le Web agentique et l'horizon	20

12.1	Ce qui est établi	20
12.2	Où elle se contredit	21
12.3	Ce que la littérature ne traite pas	21
13	Ce que la littérature établit, et où elle se contredit	21
13.1	Un défaut de fond unique, décliné en trois matières	21
13.2	L'instrument de mesure est le maillon faible	22
13.3	Proposer n'est pas prouver	22
14	Trois énoncés de la veille mis à l'épreuve	23
14.1	1. « Au-delà de deux sauts de délégation, aucun mécanisme normalisé ne maintient de traçabilité opposable. »	23
14.2	2. « L'arrimage entre la couche d'orchestration installée et la pile agentique est unilatéral. »	23
14.3	3. « Aucun attribut du socle d'observabilité agentique ne décrit une chaîne de mandat ou de délégation. »	24
15	Lacunes et programme de recherche	24
16	Limites de cette revue	25
17	Conclusion	25
	Annexe : le corpus arbitré, et ce qu'il ne couvre pas	25
	Références	27

Mots-clés — revue de littérature ; interopérabilité des agents ; IA agentique ; Model Context Protocol ; Agent2Agent ; systèmes multi-agents ; identité non humaine ; chaîne de délégation ; révocation ; sécurité des agents ; injection d'invite indirecte ; bancs d'essai d'agents ; observabilité agentique ; provenance ; paiements agentiques ; collusion algorithmique ; gestion des processus d'affaires ; exécution durable ; conformité ; responsabilité ; Web agentique ; régime de preuve ; prépublication.

1 Introduction

L’interopérabilité des agents fondés sur les grands modèles de langue est passée, en moins de trois ans, du statut de curiosité de laboratoire à celui de question d’architecture d’entreprise. Des protocoles de composition ont été publiés, des registres montés, des mécanismes de paiement et de délégation proposés, des textes réglementaires adoptés qui s’appliquent à ces systèmes sans les nommer. La production académique a suivi le même rythme. C’est précisément ce rythme qui pose problème : une littérature qui double de volume en douze mois n’a pas eu le temps d’être filtrée par les procédures qui, ailleurs, séparent le résultat de la revendication.

1.1 Question de revue

Cette revue pose une question en deux parties : **que la littérature académique établit-elle réellement sur l’interopérabilité et l’orchestration agentiques en entreprise, et à quel régime de preuve ?** La seconde partie commande la première. Un énoncé de la forme « tel protocole présente telle vulnérabilité dans tel pourcentage des serveurs observés » n’a pas la même portée selon qu’il provient d’une mesure sur un parc réel, d’une simulation, ou d’un raisonnement sur la spécification ; et il n’a pas la même autorité selon qu’un comité de lecture l’a examiné ou que son auteur l’a déposé la semaine dernière.

Trois termes sont pris au sens suivant. L’*interopérabilité* désigne la capacité de composer des agents, des outils et des services hétérogènes sous un vocabulaire commun, qu’il s’agisse d’accès aux outils, de communication entre agents ou de découverte. L’*orchestration* désigne la conduite d’un travail à plusieurs étapes, avec ses garanties d’exécution, sa trace et sa reprise sur défaillance. La restriction *en entreprise* écarte les travaux qui n’envisagent que l’agent isolé ou le banc d’essai jouet, et retient ceux qui portent sur des systèmes soumis à une contrainte d’exploitation, d’audit ou de droit.

1.2 Rapport à la veille technologique

Cette revue prolonge une veille technologique du même auteur, arrêtée au 8 août 2026, qui dresse l’état du champ sur sources primaires : spécifications, dépôts de code, communiqués de fondations, textes réglementaires. L’auto-citation est déclarée ici et signalée à chaque renvoi. Les deux exercices ne répondent pas à la même question et ne se valident pas l’un l’autre.

La veille dit ce que le monde déployé fait ; la présente revue dit ce que la littérature sait. Les deux ne coïncident pas, et l’intérêt est là. La veille observe des protocoles adoptés à grande échelle sans démonstration de sécurité publiée ; la littérature, elle, mesure des vulnérabilités sur des parcs que personne n’a mandat de corriger. La veille constate des couches comblées hors de la couche commune ; la littérature les traite parfois abondamment, parfois pas du tout. Trois énoncés de la veille sont repris en fin de revue et confrontés à ce que la littérature en dit ; deux en ressortent modifiés.

2 Méthode

2.1 Constitution du corpus

Le corpus compte 161 entrées et a deux origines. La première est le socle hérité de la veille : ses 50 pièces académiques [1-50], reprises telles quelles puis re-vérifiées pièce à pièce contre

leur notice courante, plusieurs ayant été révisées depuis leur lecture initiale. La seconde est une passe de recherche neuve conduite sur neuf fronts thématiques : protocoles [51-63], sécurité [64-74], identité et délégation [75-87], systèmes multi-agents [88-101], évaluation et observabilité [102-113], couche transactionnelle [114-125], processus d'affaires [126-137], gouvernance [138-148], Web agentique et horizon [149-158]. Trois pièces à DOI [159-161] complètent l'ensemble : textes normatifs et littérature d'ingénierie antérieure au dépôt, sans laquelle le front transactionnel n'aurait pas de point d'appui.

Les deux origines ne portent pas le même régime de citation, et le contrôle de publication de cette revue l'exige : **chacune des 111 entrées hors socle — les 108 de la passe neuve et les trois à DOI — est discutée nommément** dans le corps, tandis que le socle hérité est repris en bloc — **vingt-trois de ses cinquante pièces y sont engagées une à une, vingt-sept ne le sont pas** et ne valent ici que comme arrière-plan. *Une plage citée en prose couvre une référence sans la discuter ; le distinguer est ce qui empêche une bibliographie de grossir sans que le texte y gagne.*

Le découpage en neuf fronts n'est pas une taxinomie du champ mais un plan de couverture. Il sépare ce que la veille avait identifié comme des couches distinctes de la pile — la composition, sa sécurité, l'identité de qui agit, la coordination entre plusieurs agents, la mesure de ce qu'ils font, la garantie d'exécution, l'insertion dans les processus existants, l'encadrement juridique, et l'extension au Web ouvert. Un même travail peut relever de deux fronts ; il est alors rattaché à celui où sa mesure porte, et non à celui que son titre annonce.

La passe neuve a été conduite par des agents indépendants, à consigne de source primaire exclusive : aucun ne pouvait retenir une pièce sur la foi d'un résumé secondaire, chacun devait ouvrir la notice de chaque pièce et en rapporter les métadonnées. Le critère de rétention est la conséquence : les pièces les plus conséquentes de chaque front, la conséquence se jugeant à la mesure produite et non à la citation reçue. Sur un corpus dont 58 % a moins de huit mois, le compte de citations ne mesure rien d'autre que l'antériorité de dépôt.

2.2 Régime de vérification

Toutes les notices arXiv ont été reprises à l'API d'exportation du dépôt le 9 août 2026. Cette reprise a donné, pour chacune des 158 pièces : titre exact, auteurs, version courante, date de dépôt initial, date de dernière révision, champ `journal_ref` et champ `comment`. Elle a corrigé plusieurs statuts que les agents avaient rapportés comme « à comité de lecture » sur la seule foi du champ de commentaire — correction qui a motivé la section suivante et, plus largement, la construction de toute la revue.

La règle appliquée est stricte : seule une attestation portée à la notice elle-même — champ `journal_ref` ou champ DOI — vaut publication établie. ⚠ *Le premier relevé de cette revue ne retenait que le premier des deux champs et comptait sept pièces là où il y en a douze ; l'écart a été trouvé en confrontant les notices aux entrées, et il est rapporté ici plutôt que corrigé en silence.* Une acceptation annoncée ailleurs est enregistrée comme telle, comme déclaration de l'auteur, et comptée séparément.

2.3 Ce que cette revue ne peut pas établir

Il n’y a pas de protocole systématique au sens PRISMA : ni question enregistrée avant recherche, ni diagramme de flux, ni critères d’exclusion arrêtés d’avance. Il n’y a pas de double codage : un seul jugement décide de la rétention et de la lecture de chaque pièce. La recherche n’est pas exhaustive et n’est pas multi-bases ; elle porte sur arXiv, complété de six références connues à DOI, sans balayage de Scopus, Web of Science ni des bibliothèques des sociétés savantes — ce qui sous-représente mécaniquement les communautés qui publient d’abord en revue ou en actes fermés. Le biais anglophone et arXiv est entier et non corrigé.

Surtout, il n’y a **aucune réplcation**. Aucune expérience rapportée ici n’a été refaite, aucun jeu de données n’a été recompté, aucun banc d’essai n’a été réexécuté. La revue rapporte ce que les pièces revendiquent, en distinguant systématiquement ce qui est mesuré de ce qui est avancé. Les décomptes qui suivent sont donc un recensement du corpus retenu, non une estimation du champ.

3 Physionomie du corpus

3.1 Ce que la forme du corpus dit avant son contenu

Avant tout énoncé de contenu, la forme du corpus le qualifie. Sur les 158 pièces déposées sur arXiv, **douze** portent une attestation de publication dans leur notice. Sept la portent au champ `journal_ref` : [37] (*Künstl Intell*, 2024), [38] (actes PMAI 25, CEUR vol. 4087), [15] (ICAART 2026), [59] (actes MSR “26), [46] (actes ICML 2024), [143] (*European Journal of Risk Regulation* 16, p. 1519-1534) et [136] (*Information Systems*, vol. 142, art. 102761). Cinq de plus la portent au champ DOI : [4] (*IEEE Transactions on Cognitive Communications and Networking*), [44] et [144] (actes FAccT 2026), [142] (actes REALM 2025) et [158] (actes ACM). Vingt-six pièces annoncent une acceptation dans le seul champ de commentaire libre. Les 120 restantes ne présentent aucun signe de revue par les pairs.

Trois régimes de preuve se distinguent donc, et la distinction n’est pas formelle. Le champ de commentaire est rempli par l’auteur et n’est vérifié par personne, de sorte qu’une revue qui l’accepte pour preuve importe l’auto-déclaration au cœur de son appareil. La plupart de ces vingt-six annonces sont vraisemblablement exactes ; l’objection ne porte pas sur leur véracité individuelle mais sur la nature de la garantie, qui est procédurale et non statistique. Un contrôle que nul n’exerce ne devient pas un contrôle parce que les déclarants sont honnêtes.

Tableau 1. – Régimes de preuve des 158 pièces déposées sur arXiv, d’après les notices reprises à l’API du dépôt le 9 août 2026.

Régime	Pièces	Part
Publication attestée en notice (<code>journal_ref</code> ou DOI)	12	8 %
Acceptation auto-déclarée (champ de commentaire)	26	16 %
Aucun signe de revue par les pairs	120	76 %
Total	158	100 %

L'âge du corpus va dans le même sens. Le dépôt initial se répartit ainsi : 2023, cinq pièces ; 2024, treize ; 2025, quarante-neuf ; 2026, quatre-vingt-onze — soit 58 % du corpus déposé dans les huit premiers mois de 2026. La révision suit : 105 pièces sur 158, soit 66 %, ont été révisées pour la dernière fois en 2026, à raison de sept révisions en mars, vingt en avril, vingt et une en mai, vingt-six en juin, dix-huit en juillet et quatre dans les neuf premiers jours d'août. Quant à la stabilité des textes, 81 pièces en sont encore à leur version initiale, 44 à la deuxième, 23 à la troisième et 10 à la quatrième ou au-delà : la moitié du corpus n'a jamais été révisée.

La cadence de révision mérite une lecture propre. Vingt-six révisions en juin sur un corpus de 158 pièces signifient qu'un sixième des textes a bougé en un mois. Une pièce lue en avril et citée en août peut avoir changé de résultat, de jeu de données ou de conclusion entre-temps ; c'est ce qui a imposé la re-vérification du socle plutôt que la reprise de la lecture antérieure. Le corpus est ici gelé au 9 août 2026, et chaque énoncé rapporté vaut pour la version courante à cette date.

Le constat qui en découle commande la lecture de tout ce qui suit. Un champ dont 76 % des énoncés n'ont franchi aucun comité, dont 58 % a moins de huit mois et dont la moitié n'a jamais été révisée ne peut pas fonder une décision d'architecture au même titre qu'une littérature établie. Cela ne rend pas ces travaux sans valeur — plusieurs portent des mesures que rien d'autre ne fournit — mais cela interdit de les traiter comme un acquis, et impose de rapporter chaque résultat avec le régime qui le porte.

3.2 Répartition par front et par régime de preuve

Tableau 2. – Répartition des 161 entrées par front, avec la plage de références correspondante.

Front	Plage	Pièces
Socle hérité de la veille	[1-50]	50
Protocoles	[51-63]	13
Sécurité	[64-74]	11
Identité et délégation	[75-87]	13
Systèmes multi-agents	[88-101]	14
Évaluation et observabilité	[102-113]	12
Couche transactionnelle	[114-125]	12
Processus d'affaires	[126-137]	12
Gouvernance	[138-148]	11
Web agentique et horizon	[149-158]	10
Pièces à DOI	[159-161]	3

Les neuf fronts neufs comptent 108 pièces, de dix à quatorze chacun. Cet équilibre est un artefact de méthode, non une mesure : le critère de rétention est comparatif à l'intérieur de chaque front, et non proportionnel au volume produit sur le front. Le tableau mesure donc l'attention de cette revue, pas l'activité de la littérature.

Le régime de preuve, lui, ne se distribue pas uniformément. Cinq des douze publications attestées appartiennent au socle hérité — [4], [37], [38] et [46], antérieures à 2025, et [15] ; les sept autres se répartissent entre protocoles [59], transactionnel [44], processus d'affaires [136], gouvernance [142], [143], [144] et horizon [158]. Six fronts neufs sur neuf — sécurité, identité et délégation, systèmes multi-agents, évaluation et observabilité, couche transactionnelle, Web agentique et horizon — n'en comptent aucune. La publication attestée se produit là où des communautés établies existent depuis longtemps : gestion des processus d'affaires, systèmes d'information, droit. Elle est absente là où le champ se construit, c'est-à-dire là où portent les questions d'interopérabilité elles-mêmes.

4 Les protocoles d'interopérabilité

4.1 Ce que la littérature établit

La sous-spécification de la couche sémantique est passée du statut de « défi ouvert » des surveys [1], [2] à celui de résultat mesuré, par quatre chemins indépendants. Empiriquement : sur 856 outils de 103 serveurs MCP, 97,1 % des descriptions portent au moins un défaut et 56 % n'énoncent pas clairement leur objet ; les enrichir ne gagne que 5,85 points médians de succès, allonge l'exécution de 67,46 % et régresse dans 16,67 % des cas [53]. Sur 19 200 paires description/code issues de 2 214 serveurs réels, 9,93 % sont incohérentes, sans qu'aucun mécanisme du protocole ne vérifie que la description reflète l'implémentation [55]. Formellement : MCP et Schema-Guided Dialogue sont bisimilaires sous une application dont l'inverse est partielle et à perte, ce qui démontre au lieu de conjecturer les manques d'expressivité de MCP [56]. Analytiquement : sur 18 protocoles, transport, schéma et cycle de vie sont mûrs, mais clarification, alignement de contexte et vérification restent hors protocole [62].

Deuxième acquis, l'écosystème déployé ne se conforme pas aux hypothèses de la littérature de protocole. Sur 1 723 applications consommatrices, seules 37,2 % imposent une approbation bloquante avant exécution d'outil, le protocole ne spécifiant pas le côté client [54]. Le registre officiel n'est pas stable : sur 88,6 jours, 8,6 % de serveurs réécrivent une description, la moitié des changements atterrissant sur des arrivants qu'un classement par dérive ne peut atteindre, d'où un ré-audit ciblé couvrant environ 10 % des changements [58]. Enfin, sur 2 297 projets validés (précision 83 %), une strate purement pédagogique doit être exclue sous peine de gonfler toute mesure d'écosystème [59].

Troisième acquis, aucun protocole ne s'impose et la question s'est déplacée vers la composition : l'analyse séparée de MCP et A2A crée un fossé sémantique, que le premier cadre unifiant les deux formalise en 30 propriétés temporelles [60] ; la seule comparaison adossée à deux implémentations de la même tâche conclut que la répartition des responsabilités de coordination, non les fonctionnalités, sépare les deux protocoles, ses auteurs qualifiant ce résultat d'observations de conception [57] ; la seule interopération hétérogène publiée superpose une spécification déclarative à un protocole industriel au lieu de le remplacer [61]. Une position minoritaire récuse l'unité d'échange : l'intention représentée comme programme typé par effets réduit la latence jusqu'à 53,4 % et le trafic client jusqu'à 96,1 % [63].

4.2 Le désaccord : prévalence mesurée ou prévalence héritée

Une ligne de travaux mesure l'écosystème MCP et alarme ; un travail mesure l'instrument et l'invalidé. Sur 64 611 serveurs uniques dont 37 288 analysables dynamiquement — extension du jeu de données [52] —, les scanners qui déclarent 96,89 % des serveurs « à risque » présentent moins de 50 % de vrais positifs à la validation manuelle et se contredisent entre eux [51]. Le désaccord n'est pas de vocabulaire : deux corpus réels, une divergence sur la validité de l'outil, aucune réplification par un tiers. Deux traits l'aggravent, documentés par les pièces elles-mêmes. Monoculture méthodologique : les études de sécurité MCP partagent un même dispositif, l'audit d'un registre à un instant unique, et aucune n'a mesuré la durée de validité du texte qu'elle juge [58]. Chiffre hérité : le taux de 96,89 % provient de scanners appliqués à peu de cas et se propage par citation — repris, non reproduit [51].

4.3 Ce qu'elle ne traite pas

Manque vérifiable : aucune publication ne rapporte un taux mesuré d'échec, de latence ou de perte sémantique pour une tâche traversant deux protocoles distincts dans un système déployé, sur corpus reproductible. Toutes les mesures d'écosystème portent sur MCP seul [51], [53], [54], [55], [58], [59] ; la seule comparaison implémentée est un scénario unique dont les auteurs récusent la généralisation [57] ; la seule interopération hétérogène démontrée ne rapporte aucun taux d'échec [61]. Corollaires : aucune mesure longitudinale pour A2A, ACP ou ANP [58] ; aucune propriété formelle vérifiée sur un déploiement réel — 30 propriétés définies sans vérification [60], une équivalence prouvée sans évaluation sur agents [56].

5 La sécurité des agents et de leurs protocoles

5.1 Ce que la littérature établit

Le défaut de fond n'est pas dans le modèle : c'est l'absence d'isolation entre contenu de confiance et contenu non fiable. Quatre pièces y aboutissent par des voies distinctes. La famille des injections de *donnée* — charge déguisée en identifiant de ressource, en origine de données ou en format de réponse d'outil, échappant donc aux défenses conçues contre l'injection d'instruction — est démontrée sur six agents commerciaux nommés, et le diagnostic y est posé comme tel [64]. L'analyse de cause racine des chaînes d'outils parasites, sur 12 230 outils de 1 360 serveurs, l'identifie sous sa forme jumelle : MCP n'offre ni isolation contexte-outil, ni moindre privilège [66]. Le banc de 202 paires injection-tâche sur les fichiers de compétences conclut que ni l'échelle des modèles ni le filtrage d'entrée n'y suffiront [68]. La seule proposition constructive du lot en tire la conséquence : convertir la donnée non fiable en types de portée et de contenu bornés [74].

Deuxième acquis, mesuré sur un même banc : la capacité aggrave l'exposition et l'alignement ne protège pas. Sur 45 serveurs vivants, 353 outils authentiques et 1 312 cas de test évalués sur 20 agents, l'empoisonnement de métadonnées atteint 72,8 % de succès, la susceptibilité croît avec la capacité du modèle, et le taux de refus le plus élevé reste inférieur à 3 %, l'attaque n'employant que des outils légitimes [67]. Un second banc atteint 80 % sur les modèles de pointe [68].

Troisième acquis, décisif pour la lecture de tout le front : les scores de défense obtenus sur bancs statiques ne survivent pas à l'adaptatif. Une défense mesurée à 0 % de succès d'attaque en

statique remonte à 28 % au global et 64 % sur les tâches où l'action elle-même est déléguée à du contenu contrôlé par l'attaquant, dès qu'une optimisation en boîte noire et à bas coût la cible [71]. L'audit de dix défenses sur 560 cas conclut qu'aucune n'est déployable, chacune payant sa sécurité en fonctionnalité ou n'achetant rien [72]. Sur six systèmes multi-agents et 1 356 cas, les défenses mises au point en environnement simplifié ne transfèrent pas et peuvent créer de nouvelles vulnérabilités [69]. Trois mécanismes de contrôle d'accès publiés tombent à 86,3 % de contournement pour 4,4 % de dégradation d'utilité [73]. Deux attaques enfin sont opposables en production : 14 scénarios contre des assistants déployés, dont 73 % classés en risque élevé à critique avant mitigation par l'éditeur [65], et la famille précitée [64].

5.2 Où elle se contredit

Premier désaccord, le coût d'utilité de la prévention par construction. Le typage de la donnée non fiable revendique une prévention systématique assortie d'une utilité « forte et non triviale » [74] — revendication adossée à des études de cas non dénombrées, donc auto-évaluation et non évaluation adverse. Deux mesures indépendantes disent l'inverse : l'audit de dix défenses trouve que celles qui tiennent le font par des mesures excessivement défensives dégradant la fonctionnalité [72] ; et le travail qui obtient pourtant le meilleur rabattement du front, de 85–100 % à 0–5 % sur quatre architectures de mémoire, qualifie le déploiement réel de problème ouvert à cause d'un coût d'utilité très variable [70].

Second désaccord, plus lourd. L'écosystème MCP est déclaré criblé de *gadgets* exploitables en conditions réelles, sur 12 230 outils et 1 360 serveurs [66] ; sur un corpus cinquante fois plus grand, l'instrument qui produit ce type de constat est montré faux à plus de moitié [51]. Les deux ne peuvent décrire correctement le même parc, et il faut le dire dans ses conséquences : ce désaccord entame la valeur probante de tous les pourcentages de prévalence du front, y compris ceux repris par les surveys [3], puisque soit la sévérité est sous-décrite, soit une part importante des taux publiés est un artefact d'outil.

5.3 Ce qu'elle ne traite pas

Aucune pièce ne mesure quoi que ce soit sur un parc d'entreprise en exploitation. Les tailles d'échantillon se comptent en serveurs (64 611 ; 1 360 ; 45), en outils (12 230 ; 353), en cas de test (1 356 ; 1 312 ; 560 ; 202), en modèles ou agents (20 ; 6 implémentations), en produits (6 nommés ; 14 scénarios) — jamais en organisations, en déploiements ni en incidents observés, sans aucune télémétrie de production. Il n'existe donc aucun taux de base : on sait qu'un agent est exploitable à 72,8 % en banc [67], on ignore quelle fraction des agents en service est effectivement attaquée. Deux lacunes de second rang : la seule pièce inter-agents reste intra-système [69], rien ne portant sur la chaîne d'appel inter-organisationnelle ; et si la fiabilité des scanners a été auditée [51], celle des bancs d'attaque ne l'a pas été.

6 L'identité, la délégation et la révocation

6.1 Ce que la littérature établit

La convergence la plus forte du corpus porte sur l'atténuation : l'autorité doit décroître à chaque saut au lieu de se transmettre intacte, et le jeton porteur relayé tel quel est unanimement tenu pour le mauvais primitif. Elle est obtenue par des travaux qui ne partagent ni méthode ni objet :

atténuation de portée de ressource comme opérateur compositionnel, avec preuves formelles et évaluation d’applicabilité [83] ; rétrécissement d’autorité mécaniquement vérifié en TLA+ sur 2,7 M d’états, aux côtés du confinement de cascade et de la restructurabilité forensique [76] ; chaîne append-only où chaque saut est signé et vérifiable hors ligne, contre l’incapacité d’OAuth 2.0 et des JWT à porter une délégation multi-sauts autorisée par un humain [77] ; capacités bornées par époque se fermant à l’achèvement de la tâche [87]. Le socle proposait déjà des jetons de capacité liés à l’invocation [16].

Deuxième convergence : la validité doit être liée à un événement, non à une horloge. Trois travaux indépendants, qui ne se citent pas et ne partagent ni domaine d’application ni vocabulaire, obtiennent des gains d’ordre cent sur les baux temporels et sur OAuth 2.0.

Tableau 3. – Tableau 2. Trois voies indépendantes vers une validité liée à un événement.

Pièce	Événement liant la validité	Gain rapporté	Référentiel
[75]	compteur d’exécutions, cohérence dirigée	$D \leq n$, indépendant de la vitesse de l’agent ; 120–184×	baux temporels
[80]	preuve périodique de vivacité du parent	~90× sur la fenêtre d’agent zombie	OAuth 2.0
[87]	achèvement de tâche, poignées bornées par époque	fermeture de l’accès futur, sans facteur chiffré	autorité résiduelle

Troisième acquis : l’identité ne suffit pas, c’est l’action qu’il faut prouver. Le contexte de délégation doit être lié pendant l’exécution et non reconstitué après [84] ; la preuve d’action doit être ancrée plutôt que déclarée par l’opérateur [86] ; chez les identités non humaines, une modélisation à l’échelle d’une flotte infonuagique réelle montre que le sur-privilège est un régime temporel et non un état [82]. Le terrain ne tient pas le socle à un seul saut : sur 7 973 serveurs MCP distants, 40,55 % exposent des outils sans aucune authentification, les failles d’enregistrement dynamique de client touchent 96,6 % des serveurs testés [81] ; près de 100 000 enregistrements d’identité multi-chaînes confirment une infrastructure immature [42]. La vérification formelle des spécifications relève enfin 35 lacunes de spécification et 30 défaillances nées de la seule composition : un seul protocole applique effectivement un contrôle de sécurité, aucun n’assigne la responsabilité d’application au comportement inter-protocoles [85].

6.2 Où elle se contredit

Premier désaccord, l’emplacement de la racine de confiance et son prix opérationnel. Une position soutient qu’aucune preuve d’action n’est opposable sans ancrage matériel — architecture IETF RATS composée avec des paquets de preuves d’action et une mesure d’intégrité TPM, l’objet vérifié étant la production effective de la sortie par la version de modèle annoncée sur du matériel non modifié [86]. Deux travaux revendiquent l’opposabilité sans matériel spécialisé ni vérificateur en ligne : vérification hors ligne à la seule clé publique Ed25519 de l’émetteur [77] ; fraîcheur appliquée avec les seules clés en cache et l’horloge locale du vérificateur [80]. Le

désaccord est symétrique dans ses coûts : le premier camp exige une infrastructure d’attestation que la quasi-totalité des parcs d’entreprise n’a pas ; le second accepte structurellement qu’un agent compromis mais vivant signe des sauts parfaitement valides.

Second désaccord, un arbitrage de type CAP déguisé en question d’identité. Borner les opérations non autorisées indépendamment de la vitesse de l’agent suppose, par l’analogie même avec la cohérence mémoire qui fonde le résultat, un point de sérialisation partagé [75]. L’autre position refuse tout aller-retour réseau au moment de la vérification et assume en contrepartie une fenêtre résiduelle égale à l’intervalle de battement [80]. Aucune des deux pièces ne reconnaît la position adverse : le champ n’a pas nommé l’arbitrage qu’il pratique.

Ces désaccords se lisent mal sans distinguer proposer, prouver et normaliser. Des mécanismes multi-sauts explicites existent [77], [16] ; une chaîne de profondeur arbitraire est opposable quant à la portée des actions, mais la préservation d’intention est réputée pratiquement infaisable de manière déterministe [76], et une borne de propagation de responsabilité est établie sans validation empirique, de l’aveu de son auteur [78] ; rien n’est normalisé et aucune application inter-protocoles n’est assignée [85]. L’obstacle est de normalisation et d’instrumentation, non d’invention.

6.3 Ce qu’elle ne traite pas

Toutes ces pièces bornent la fenêtre pendant laquelle un agent révoqué agit encore ; aucune ne dit ce qu’il advient des effets et des sous-délégations déjà émis quand un saut amont est invalidé après coup. Il n’existe ni sémantique de compensation en cascade, ni critère décidant quels effets aval sont annulables, ni preuve qu’une invalidation amont soit propageable aux sous-délégations qu’elle a autorisées. La lacune est vérifiable par lecture : un compte d’opérations non autorisées est borné [75], une fenêtre est bornée [80], un accès futur est fermé [87] — tous en régime purement préventif. Deux constats l’aggravent : des traces d’exécution identiques peuvent correspondre à plusieurs assignations de délégation mutuellement incompatibles, si bien que l’ensemble des effets à compenser n’est pas calculable a posteriori [84] ; et aucun des quatre régimes réglementaires européens examinés — règlement IA, RGPD, règlement Machines, directive Responsabilité du fait des produits — ne définit à qui incombe cette compensation, la dégradation de la chaîne de consentement restant non traitée dans ses dimensions centrales [79]. Chaîmer les droits de manière vérifiable ne dit rien du chaînage des conséquences.

7 Les systèmes multi-agents : orchestration et défaillance

7.1 Ce que la littérature établit

Le résultat le plus robuste de ce front n’est pas un score, c’est une incapacité. Sur les journaux d’échec de 127 systèmes multi-agents, la meilleure méthode automatique d’attribution n’identifie l’agent fautif que dans 53,5 % des cas et l’étape décisive dans 14,2 %, plusieurs méthodes — dont des modèles à raisonnement explicite — faisant moins bien que le hasard [88]. Ce plafond tient à l’instrumentation plus qu’à la difficulté du problème : rendre la trace complète observable — entrées et contexte, non les seules sorties — porte l’attribution jusqu’à 76 % [89]. La taxonomie MAST, sur plus de 1 600 traces annotées, impute ces échecs à la coordination plutôt qu’au modèle de base [48], et la modélisation de la propagation d’erreur sur graphe de dépendances montre, sur six cadriciels, qu’une erreur atomique unique suffit à

figer un faux consensus [90] — la coordination se laissant isoler comme couche architecturale, à modèle, outils et invite figés [91].

Deuxième acquis : le rendement du multi-agent est non monotone. Un agent unique bien invité égale presque la meilleure discussion multi-agents sur un large éventail de tâches, la discussion ne l'emportant que lorsque l'invite ne contient aucune démonstration [92] ; l'analyse de 245 caractéristiques sur six bancs donne l'agent unique gagnant dans environ 43,3 % des cas, les dynamiques d'entropie se fixant dès les premiers tours [95] ; les architectures engendrées automatiquement restent en deçà de la chaîne de pensée avec auto-cohérence pour un coût jusqu'à dix fois supérieur [94]. La littérature favorable ne contredit pas ce point : la loi d'échelle collaborative établie jusqu'à plus d'un millier d'agents est logistique, donc saturante [96], et l'optimisation entrelacée invites-topologie-invites établit surtout que la performance dépend davantage du réglage des invites que du patron topologique retenu [97]. Le surcoût de coordination est mesurable et partiellement récupérable : $1,15\times$ à $2,3\times$ selon le patron sur 10 000 dépôts SEC rejoués [98], $-29,68\%$ de jetons sans perte de succès sur GAIA par supervision d'exécution [99].

7.2 Où le désaccord est réel

Le clivage sur l'utilité même du multi-agent suit la méthode plutôt que l'objet : les pièces favorables évaluent leur propre architecture, optimisée, contre des lignes de base qui ne le sont pas ; les défavorables évaluent celles d'autrui contre une ligne de base forte — invite riche, auto-cohérence, ensemblage. Une pièce tranche partiellement le litige : le débat multi-agents n'est pas intrinsèquement inférieur, il est hypersensible aux hyperparamètres et redevient compétitif après réglage [93]. Il s'ensuit que tout résultat de ce front mesure d'abord l'effort de réglage consenti à chaque bras, qu'aucune des quatorze pièces n'égalise.

Tableau 4. – Le résultat covarie avec la provenance du système évalué : sur quatorze pièces, quatre annoncent un comité de lecture, onze évaluent une construction de leurs auteurs, et les quatre seules évaluations indépendantes contre ligne de base forte sont celles qui concluent au non-avantage.

Position	Système évalué	Ligne de base	Pièces
Avantage du multi-agent	architecture des auteurs	non optimisée	[96], [97]
Non-avantage	architecture de tiers	forte	[92], [93], [95], [94]

Un second désaccord porte sur ce que résout la traçabilité. L'observabilité complète des traces est posée comme levier principal de diagnostic [89] ; mais un canal d'état échappe par construction aux détecteurs déployés, un contexte toxique compressé en résumé passant sous leur seuil tout en augmentant la toxicité en aval [100] — instrumenter davantage et gouverner l'écriture en mémoire sont deux corollaires opposés. Le partage se rejoue sur la supervision : légère et machine, elle réduit le coût sans perte [99] ; humaine et fatigable, elle suit un U inversé, au-delà d'un seuil d'escalade davantage de supervision dégradant la sécurité réalisée (125 actions étiquetées, kappa de Fleiss = 0,52, auteur unique) [101].

7.3 Ce qui n'est pas traité

Aucune pièce ne mesure un assemblage multi-agents en exploitation d'entreprise, sur une durée et un volume réels, avec un taux de défaillance observé. Les mesures portent sur des bancs académiques, des corpus hors ligne (10 000 documents [98]), des marchés de prédiction (100 marchés [91]) ou des journaux rassemblés a posteriori (127 systèmes [88]) ; le chiffre de 41 à 87 % d'échec « en production » qui circule est repris de la littérature par [91], non produit par son protocole. Manque également toute comparaison contrôlée des patrons d'orchestration — superviseur, transfert, graphe, marché — à modèle, invite, outils et budget figés sur plusieurs domaines : [98] s'en approche sans comité de lecture, sur un domaine unique ; [91] fige les variables sur cinq configurations d'un seul modèle.

8 L'évaluation, les bancs d'essai et l'observabilité

8.1 Ce que la littérature établit

Le score publié n'est pas ce qui s'observe, et trois voies indépendantes l'établissent. Défauts de conception : tests insuffisants, réponses vides comptées comme succès et récompenses mal spécifiées faussent les scores des bancs les plus utilisés [107]. Généralisation : une part substantielle de la performance sur SWE-bench Verified relève de la mémorisation du dépôt, les mêmes modèles chutant fortement sur des tâches hors distribution appariées [108]. Enchaînement en exploitation : sur une chaîne de construction de compilateur à dépendances sérielles, la réussite s'effondre de 100 % au premier étage à 20 % au dernier, aucun des 15 modèles n'achevant le pipeline [105]. Les bancs d'entreprise donnent la même pente : environ 30 % de tâches professionnelles achevées en autonomie dans une entreprise logicielle simulée [102], 58 % en tour unique contre 35 % en multi-tours sur des scénarios d'affaires [104].

Deuxième acquis : le coût et le régime d'exécution sont des dimensions d'évaluation, non des annexes. L'exactitude seule est vide de sens sans axe de coût, et l'absence de jeu de retenue rend les scores irreproductibles [106] ; en exploitation, la dépense varie de trois ordres de grandeur entre modèles de qualité comparable [105] ; le prix de l'auditabilité se chiffre à son tour, 8,3 ms de surcoût médian pour une médiation pré-exécution à traces infalsifiables, sur 617 constats relevés dans six projets ouverts [113].

Troisième acquis : la trace est devenue l'objet évalué, et les modèles la lisent mal. Sur 148 traces annotées par des humains, collectées au format d'observabilité réellement déployé, le meilleur modèle à long contexte n'atteint que 11 % en localisation d'anomalie [111]. La provenance doit relier l'invite, la décision, l'appel d'outil et le résultat en aval [112] ; l'auditabilité se décompose en cinq dimensions dont l'attribution de responsabilité, précisément celle qui manque aux systèmes mesurés [113].

8.2 Où le désaccord est réel

Le litige dur porte sur l'évaluateur automatique. Une pièce conclut qu'un juge agentique, notant les étapes intermédiaires et non le seul résultat, s'approche de la fiabilité humaine à une fraction du coût [110]. Une autre démontre l'inverse au niveau du principe : dès lors que le juge n'est pas plus exact que l'évalué, aucune méthode de débiaisage ne réduit de plus de moitié le besoin d'étiquettes de référence [109]. Le désaccord oppose une mesure empirique à un plafond

théorique et n'est pas dissoluble par davantage de données ; la mesure empirique est de surcroît auto-arbitrée, les mêmes auteurs publiant le banc (55 tâches, 365 exigences) et le juge qui y domine [110]. Deux autres conflits d'intérêts sont vérifiés : un banc d'entreprise partage quatre auteurs avec le système de référence qu'il mesure [102], [103] ; un banc d'affaires est publié par le fournisseur du produit agentique concurrent du domaine évalué [104].

Second désaccord : l'auditabilité s'obtient-elle par lecture a posteriori de la trace ou par médiation à l'exécution ? Le programme dominant instrumente puis analyse [111], [112]. Une pièce le tient pour structurellement borné : deux attributions de mandat incompatibles peuvent produire des traces strictement identiques, la télémétrie usuelle étant sémantiquement insuffisante pour reconstruire la propagation d'autorité [84].

8.3 Ce qui n'est pas traité

Personne n'évalue la trace comme preuve. Les bancs d'entreprise notent l'état final [102], [104], [105] ; les corpus de traces notent la localisation d'erreur [111], [48] ; l'auditabilité est proposée comme propriété de système [113] et comme modèle de données [112], [84], jamais comme tâche mesurée. Il n'existe donc aucun banc dont le critère de réussite soit : à partir de cette trace, un tiers peut-il reconstruire qui a mandaté quoi et imputer la responsabilité ? Le symptôme se lit dans le modèle de provenance de référence, seul passé par comité de lecture sur ce point, qui étend le W3C PROV sans instancier sa relation de délégation native [112]. Les deux propositions qui lient contexte de délégation et exécution ne sont pas arbitrées : prépublication de deux auteurs [84], auto-évaluation sur banc maison [76].

9 La couche transactionnelle : paiements, marchés, réputation

9.1 Ce que la littérature établit

Le mandat signé n'est pas le point de rupture ; ses deux bords le sont. En amont, l'intention que la signature scelle est déjà falsifiable : deux injections dans le contexte d'un agent d'achat de référence détournent le classement produit et exfiltrent des données utilisateur (90 à 100 % de réussite) [116]. En aval, les garanties de signature tiennent au niveau de la spécification mais pas à l'exécution — reprises, concurrence, orchestration —, défaut qu'une vérification à consommation unique et liaison de contexte corrige en banc de charge (~3,8 ms à 10 000 tr/s) [117]. Les deux systématisations nomment le même défaut autrement : liaison d'intention faible et découplage paiement/service [115] ; autorisation traitée comme une dimension parmi cinq qu'aucun protocole ne couvre entièrement [114]. C'est la seule convergence du front où mesure et systématisation disent la même chose.

Deuxième acquis, non contesté : des agents tarificateurs en langue naturelle atteignent en oligopole des prix supra-concurrentiels sans communication explicite, l'ampleur dépendant de formulations anodines de l'invite [119]. Le phénomène est retrouvé sous auto-optimisation des invites [121] et pris comme point de départ par la pièce qui n'en discute que la stabilité [120].

Troisième acquis : la réputation telle qu'implémentée ne porte aucun signal exploitable. Sur trois chaînes, la plupart des identités enregistrées n'exposent aucun point de service actif, les scores sont Sybil-attaquables par construction et la majorité des avis n'a aucun ancrage

vérifiable [118] ; le socle établit par ailleurs que ces agents manquent de l’ancrage identitaire que présuppose tout mécanisme réputationnel [44]. Les marchés agentiques restent manipulables du côté vendeur [122], [124]. Le seul correctif qui déplace l’aiguille est économique — garantie exécutable, séquestre, sanction — et non réputationnel.

9.2 Où le désaccord est réel

La collusion algorithmique est-elle un régime ou un artefact d’homogénéité ? Des stratégies collusoires stables et généralisantes émergent dès que les agents raffinent eux-mêmes leurs invites [121] ; à l’inverse, l’hétérogénéité fait chuter le surprix de 22 % à 10 % par la patience et à 7 % par l’asymétrie d’accès aux données, et aucune collusion soutenue n’est observée sur 1 000 périodes entre Q-learning et LLM [120]. Les deux mesurent des agents simulés en oligopole et divergent sur ce qui constitue le cas de base. L’arbitrage est empirique et personne ne l’a fait : si les marchés réels convergent vers deux ou trois modèles frontière, l’homogénéité est le cas réaliste et l’hétérogénéité le laboratoire. Aucune pièce ne mesure la population effective de modèles tarificateurs.

Second litige : les agents sont-ils des agents économiques compétents ? Quasi optimaux en conditions idéales, dégradés à mesure que le nombre d’options croît [122] ; déficitaires en raisonnement stratégique en négociation libre [123] ; non superposables au comportement humain sous mêmes institutions, dans la seule pièce à se donner un étalon humain [125] ; instables au point qu’un changement de modèle réordonne les préférences d’achat [124]. Le désaccord porte moins sur les agents que sur le protocole : structurés, ils s’en sortent ; en langue libre, ils échouent. Aucune pièce ne teste les deux régimes sur le même marché.

9.3 Régimes de preuve et lacunes

Tableau 5. – Régimes probatoires des douze pièces ; la seule mesure en production porte sur un registre de réputation, non sur un flux de paiement.

Régime probatoire	Pièces	Part
Mesuré sur système déployé	[118], registres sur trois chaînes	1 / 12
Mesuré sur implémentation de référence ou banc de charge	[116], [117]	2 / 12
Simulé en environnement synthétique	[119], [120], [121], [122], [123], [124], [125]	7 / 12
Systématisé ou argumenté, sans donnée propre	[114], [115]	2 / 12

Aucune pièce ne mesure de transaction réelle à valeur réelle sur une pile de paiement agentique en exploitation : tout énoncé sur le comportement des agents payeurs repose sur de la simulation. Le seul chiffre de volume du corpus est repris d’un texte de spécification et qualifié de non audité par les auteurs eux-mêmes [114].

Première lacune : aucune pièce ne traite la responsabilité d’une transaction non autorisée. Aucun travail ne modélise la répartition entre émetteur, acquéreur, marchand et fournisseur d’agent ; aucun ne confronte un mandat correctement circonscrit au régime de rétrofacturation existant ; aucun ne mesure un taux de contestation. Le contrôle porte sur le domaine entier et ne rend qu’une pièce principal-agent conceptuelle et jamais transactionnelle [142], une cartographie de conformité muette sur le contrat et le paiement [138], et une pile assurantielle qui présuppose résolue l’allocation de responsabilité qu’elle ne traite pas [45].

Seconde lacune, plus dure : la littérature raisonne sur une pile qui n’existe pas, et la fracture est visible dans les bibliographies. La systématisation la plus complète du règlement couvre x402, MPP, ERC-4337, Permit2, EIP-8004, Kite, Skyfire et Tempo, et ne mentionne ni AP2, ni ACP, ni L402 [115] ; symétriquement, les deux pièces AP2 ignorent x402 [116], [117]. Une seule pose les piles côte à côte, conclut à la fragmentation et date l’état de maintenance des spécifications qu’elle traite : AP2 sans implémentation de référence adoptée, ERC-8004 à déploiement limité, MPP le plus mûr [114]. Personne ne propose ni ne mesure un vocabulaire de capacités partagé ; le cadre analytique en quatre étapes fabriqué a posteriori pour comparer des protocoles sans terme commun [115] est le symptôme, non le remède. Les économistes présentent l’angle mort inverse : indifférents au rail de paiement [119], [124], [125], leurs résultats survivront à n’importe quelle obsolescence de spécification, mais restent muets sur l’autorisation et le règlement. Aucune pièce ne tient ensemble la formation du prix et le rail qui l’exécute.

10 Les processus d’affaires et l’exécution durable

10.1 Ce qui est établi

L’installé est enveloppé, pas remplacé. Le mouvement dominant ne substitue pas l’agent au moteur de processus : il l’encercle. Le harnais CUGA FLO place une couche agentique régie par politiques autour d’un moteur de workflow déterministe qui conserve l’autorité d’exécution [132] ; l’agenda neuro-symbolique fait des modèles de processus typés et des contraintes de conformité des composants architecturaux de l’agent, non une surveillance externe [131] ; l’architecture CHAI subordonne le modèle de langue à un graphe DCR qui encode les obligations légales et pilote le dialogue [137]. L’agent n’intervient qu’à des points de contrôle nommés — décider, adapter, formuler — jamais sur la trajectoire entière. La ligne prolonge les travaux d’ouverture sur les modèles de langue en gestion des processus [31], [37] et le relevé des perspectives praticiennes sur la gouvernance des agents en processus [32].

La fiabilité vient d’une couche transactionnelle en aval, pas du modèle. Ce que produit le modèle y est une proposition, jamais un effet. Atomix établit que le retour d’outil est une frontière de règlement fausse et n’engage les effets externes qu’une fois écartée toute arrivée concurrente antérieure [126]. Mnemosyne soumet toute action produite par un modèle à un contrôle d’admission déterministe et démontre que la correction de l’état engagé devient indépendante de la compétence du proposant, à moins de 6 % de surcoût [127]. La formalisation en TLA+ de quatre anomalies de concurrence des exécutifs multi-agents, avec exécutif Rust prouvé, fournit à cette thèse ses premières garanties mécanisées [128]. La filiation est assumée : le patron Saga [160] plutôt que l’ACID strict, et la sémantique de l’exécution durable [161] pour la persistance de l’état.

La gouvernance passe par la conversion de la trace en journal de processus standardisé. Traduire traces de raisonnement, appels d'outils et coûts en jetons vers un modèle d'événements normalisé est posé comme la précondition de l'audit, et dix-huit praticiens tiennent la transparence comportementale pour un prérequis de la confiance [130]. Les mêmes journaux servent en retour à engendrer les agents : la fouille de processus sur les enregistrements d'un dépôt découvre les rôles propres au projet et en produit les spécifications [135]. La ligne prolonge l'observabilité de la variabilité comportementale [38] et l'évaluation des modèles sur les tâches de fouille [39] ; le programme de la gestion agentique des processus [33], [34] en fait sa condition d'entrée.

10.2 Le désaccord dur : atomicité contre réversibilité

Tableau 6. – Deux ontologies incompatibles de la fiabilité agentique, non deux réglages d'un même paramètre.

	Atomicité [126], [127], [128]	Réversibilité [129]
Unité de fiabilité	la frontière de règlement	la position de l'action sur l'échelle idempotent / réversible / compensable / irréversible
Statut de l'effet	invisible avant engagement	émis, puis révisé
Place de l'humain	hors transaction	concurrente de l'exécution
Borne de l'agent	ce qu'on peut valider	ce qu'on peut défaire

Revisable by Design rejette explicitement le paradigme transactionnel et pose que la flexibilité d'un agent est bornée par sa réversibilité [129]. Le désaccord n'est pas de degré. Sous atomicité, l'humain ne voit rien avant règlement et ne peut donc pas corriger en cours ; sous réversibilité, l'effet est visible et possiblement faux pendant un intervalle borné, et la correction est un flux, non une porte. Adopter l'un rend l'autre inatteignable : on ne peut pas simultanément suspendre l'effet jusqu'à la certitude et l'émettre pour organiser sa révision. Aucune pièce du corpus ne compose les deux régimes ni ne fournit de critère pour choisir entre eux selon la classe d'effet.

Second désaccord, moins tranché mais structurant : le modèle de processus est-il prescriptif *a priori* ou découvert *a posteriori* ? Le métamodèle BPMN étendu de constructions natives d'agent [133], le langage de protocole faisant des portes d'approbation humaine des invariants applicables [134] et le contrôleur DCR [137] écrivent le formalisme d'avance ; la génération de règles par modèle de langue relève du même geste [36]. La fouille inverse la causalité : le modèle est extrait des journaux et sert à produire les agents [135] ou la gouvernance [130]. Même communauté, directions opposées, et aucune des deux ne traite l'autre comme un cas particulier.

10.3 Ce que la littérature ne traite pas

Personne ne mesure la conformité d'exécution d'un agent à un modèle de processus. Le contrôle de conformité au sens de la discipline — aligner une trace réelle contre un modèle de référence, quantifier *fitness* et précision — n'est appliqué à aucune trace d'agent autonome. [130] produit

le journal mais s'arrête à la découverte et à la gouvernance ; [131] énonce la conformité par construction comme agenda et non comme résultat mesuré ; [136] évalue le modèle produit, jamais l'exécution. Contrôle vérifiable : la requête "conformance checking" AND "LLM" sur le dépôt rend sept entrées, dont aucune ne porte sur des traces d'agents autonomes — celles qui s'en approchent alignent des plans ou du code, pas l'exécution d'un agent contre un modèle métier.

11 La gouvernance, le risque et la responsabilité

11.1 Ce qui est établi

Aucune pièce ne réclame la personnalité juridique de l'agent. Trois disciplines aboutissent à la même structure. En droit de la responsabilité délictuelle, l'imputation se fait par type d'interaction — dérive autonome, usage-outil, planification collaborative — et les journaux d'interaction deviennent le moyen de preuve situant l'écart à l'action autorisée [140]. En analyse économique du droit, le cadre principal-agent distingue les problèmes inhérents à la délégation de ceux qui émergent de la composition multi-agents [142]. En droit du mandat, les devoirs de divulgation et de loyauté ne sont pas encodés par les architectures d'agents et doivent devenir contrainte de conception [141]. Toutes remontent au mandant humain, et toutes conditionnent cette remontée à un enregistrement d'exécution.

L'auditabilité est posée comme condition préalable de la conformité, non comme son corollaire. L'informatique le pose formellement — pas de responsabilité sans auditabilité — et le mesure : lacunes répandues dans des projets d'agents libres, surcoût faible des enregistrements infalsifiables [113]. Le droit en tire la conséquence la plus dure du corpus : un système à haut risque dont la dérive est intraversable ne peut satisfaire les exigences essentielles du règlement européen [138]. Le relevé documentaire, à cheval sur l'informatique et la politique publique, constate côté offre que la documentation de sûreté est majoritairement absente des systèmes déployés [144]. Le constat rejoint l'inexpressivité relevée des protocoles [21] et les cadres de gestion du risque [20], [159].

La supervision humaine n'est démontrée nulle part comme contrôle effectif. Le droit établit que le règlement charge la supervision humaine de corriger le biais d'automatisation sans base empirique attestant qu'elle y parvient, et avec une répartition contestable entre fournisseur et déployeur [143]. L'enquête de terrain en santé, relevant de l'informatique et de l'interaction humain-machine, observe une supervision quasi totale : non un contrôle calibré, mais un frein imposé par la responsabilité [147].

11.2 Deux désaccords, dont un de prémisse

Le premier porte sur le lieu de la défaillance réglementaire. Le droit répond que le règlement est opérationnalisable sous condition, une architecture de conformité étant constructible dans le droit existant, l'obstacle restant technique [138]. La politique publique répond que le déficit est institutionnel — surveillance, mise en application, ressources — et qu'aucune architecture côté fournisseur ne le comble [139]. La revue de gouvernance émergente cartographie ce front sans l'arbitrer, et qualifie elle-même son évaluation de préliminaire [145].

Le second est plus grave : c'est un désaccord de prémisse factuelle. La littérature juridique légifère sur des agents déployés à l'échelle, planifiant et exécutant des chaînes d'actions avec implication humaine réduite [138], [139], [140]. Les pièces empiriques documentent l'inverse : autonomie opérationnelle marginale en santé [147] ; en génie logiciel, une erreur de calibration de 43 points entre vitesse anticipée et ralentissement mesuré, et des gains quasi nuls en documentation clinique [148]. Les deux camps ne se citent pas, et ils ne sont pas arbitrables entre eux : la doctrine établit par interprétation de textes et cohérence, la mesure d'effet par entretiens codés ou observation. Une doctrine n'est pas réfutée par vingt entretiens, ni une mesure par une exégèse. La revue enregistre l'écart plutôt qu'elle ne le tranche. Les architectures de gouvernance sectorielles, du côté de la finance quantitative, ajoutent des instruments mesurables de détection de dérive, mais leur chiffre d'accroche provient d'un sondage informel et ne doit pas être repris comme mesure [146].

11.3 Ce que la littérature ne traite pas

L'écart entre ce que le droit exige et ce que les protocoles savent exprimer est nommé, jamais instrumenté. Aucune pièce ne confronte les champs d'un message de protocole aux éléments exigés par les articles 12, 14 et 26 du règlement européen. La cartographie juridique raisonne sur des catégories de déploiement et des flux de données, pas sur des schémas de messages [138] ; la mesure d'auditabilité porte sur des dépôts logiciels, pas sur la capacité d'un format d'échange à porter une identité de mandant, une portée d'autorisation ou un point d'intervention [113] ; le relevé recense des systèmes, pas des formats [144] ; le cadre délictuel fait du journal le pivot probatoire sans spécifier ce qu'il doit contenir pour tenir devant un tribunal [140]. La proposition « dérive intragable donc non-conformité » est donc énoncée comme constat normatif alors qu'elle est une hypothèse testable. Lacune connexe : toutes ces pièces supposent un mandant unique identifiable et aucune ne traite l'attribution lorsque la chaîne d'actions traverse plusieurs entités.

12 Le Web agentique et l'horizon

Ce front compte quatre mesures, dont deux arbitrées, trois propositions d'architecture, trois positions, et aucune simulation. Le registre est indiqué pour chaque énoncé, faute de quoi une proposition y prendrait le ton d'un résultat.

12.1 Ce qui est établi

Position et architectures. Le Web humain est tenu pour une interface inadaptée aux clients agentiques, et le remède est partout le même : un canal déclaratif servi par le site. Une architecture propose un domaine à double couche servant contenu humain et contenu optimisé pour agents, avec un successeur déclaré de `robots.txt` gradué par intention [149] ; une autre expose les capacités du site par des balises `<tool>` et `<context>`, avec pour seule évidence la faisabilité de construction établie sur seize développeurs [150]. Convergence de propositions, non de résultats.

Mesure, des deux côtés. Les mécanismes de consentement hérités ne contraignent pas les clients automatisés : la conformité au protocole d'exclusion décroît à mesure que la directive se durcit, et les moissonneurs de recherche par intelligence artificielle ne le consultent quasiment jamais [151] ; la détection commerciale déployée n'identifie qu'un des sept agents de navigation testés,

là où les empreintes comportementales les séparent tous [152]. Deux voies indépendantes — journaux de sites contrôlés, site-appât instrumenté — pour l'énoncé le mieux étayé du front.

Une mesure, deux positions. L'écart entre capacité annoncée et capacité réalisée n'est mesuré qu'une fois : 102 agents commerciaux et 31 participants [158]. Les explications qui en sont données — l'échafaudage externe [157], le déficit d'auto-amélioration [153] — sont des positions.

12.2 Où elle se contredit

L'autonomie est-elle une décision de conception certifiable, ou une propriété qui dérive ? *Position* : le niveau d'autonomie est un choix délibéré, séparable de la capacité et de l'environnement, et certifiable [155] ; *architecture* : il s'opérationnalise par inspection statique du code d'orchestration [156]. Or l'agent y est formalisé, ailleurs, comme un opérateur de mise à jour auto-induit dont les cibles licites sont les invites, la mémoire, les outils et la logique de contrôle — soit l'objet même de cette inspection, *position* [153] ; et un banc d'essai non répliqué mesure que cet échafaudage est la surface où une compromission devient permanente, *mesure* [154]. Un certificat établi au déploiement cesse alors d'être valide. Aucune des deux familles ne cite l'autre.

Corollaire, et point de bascule du front : l'identification coopérative postulée par les architectures [149], [150] — jusqu'à revendiquer une politique appliquée et non honorifique — est démentie par les deux mesures [151], [152]. Une propriété d'application est affirmée par conception, contredite par observation.

12.3 Ce que la littérature ne traite pas

Aucune pièce ne définit un niveau d'autonomie invariant sous auto-modification, ni ne mesure la dérive d'autonomie après évolution. Les échelles fixent l'autonomie au déploiement [155], [156] ; la littérature auto-évolutive décrit et mesure des systèmes qui réécrivent leur propre échafaudage sans jamais rapporter le niveau d'autonomie résultant [153], [154]. Les deux portent sur le même objet, sans lien établi : la gouvernance par niveaux d'autonomie n'a aujourd'hui aucune garantie de tenir sur les systèmes que ce front annonce [40], [41], [46].

13 Ce que la littérature établit, et où elle se contredit

13.1 Un défaut de fond unique, décliné en trois matières

Les neuf fronts ne partagent ni objet ni méthode, et convergent pourtant sur un énoncé qu'aucun ne porte seul : **rien, dans les piles examinées, ne sépare ce qui est autorisé de ce qui est seulement présent.** Sur le *contenu*, les agents n'isolent pas donnée de confiance et donnée non fiable [64] [66] [68], et rien ne lie une description d'outil à son code — 9,93 % de paires divergentes sur un parc réel [55], 97,1 % de descriptions défectueuses [53], 37,2 % d'applications imposant une approbation bloquante [54]. Sur l'*autorité*, le jeton porteur transmis intact est tenu pour le mauvais primitif : elle doit s'atténuer à chaque saut [83], se rétrécir sous vérification mécanique [76], se fermer à l'achèvement de la tâche [87] — mais 40,55 % des serveurs MCP distants n'authentifient rien [81]. Sur l'*effet*, la sortie du modèle est traitée comme un fait accompli quand elle n'est qu'une proposition, d'où la frontière de règlement déplacée hors du retour d'outil [126] et le contrôle d'admission rendant l'état engagé indépendant du proposant [127] ; et sur le Web, déclarer une politique n'est pas l'appliquer [151] [152].

13.2 L'instrument de mesure est le maillon faible

Trois fronts indépendants, qui ne se citent pas, y aboutissent. Les scanners de sécurité MCP déclarent 96,89 % des serveurs à risque ; validation manuelle faite, moins de la moitié des alertes sont des vrais positifs, et les scanners se contredisent entre eux [51]. Les bancs les plus employés comptent des réponses vides comme succès [107], la performance sur SWE-bench relève pour partie de la mémorisation [108], et le juge automatique bute sur un plafond démontré [109]. L'attribution de défaillance n'identifie l'agent fautif que dans 53,5 % des cas et l'étape décisive dans 14,2 %, certaines méthodes faisant moins bien que le hasard [88] — plafond imputable à l'instrumentation, puisque rendre entrées et contexte observables porte l'exactitude à 76 % [89]. **Dans ce champ, un pourcentage renseigne sur un dispositif au moins autant que sur le monde.**

13.3 Proposer n'est pas prouver

Sur les 105 pièces distinctes retenues par les neuf fronts, **56 — 53 % — rapportent le chiffre de performance d'un artefact construit par leurs propres auteurs** : système, protocole, défense, attaque ou banc. Maximum en sécurité (10/12) et en multi-agents (11/14, les exceptions étant exactement les pièces qui concluent au non-avantage) ; minimum en gouvernance (2/12) et en protocoles (4/12). Le champ ne recopie pas seulement ses chiffres : il s'auto-arbitre à moitié.

Tableau 7. – Les neuf désaccords réels du champ, un par front, avec ce qui les arbitrerait.

Front	Désaccord	Ce qui l'arbitrerait
Protocoles	MCP suffit-il à coordonner ? Oui [57] ; non, schéma prouvé à perte [56] ; prémisse récusée [63]	La même tâche dans les deux protocoles, mesurée par un tiers
Sécurité	Prévention par construction : utilité préservée [74] ou payée cher [72] [70] ?	Soumettre [74] à une attaque adaptative [71], publier le coût d'utilité
Identité	Ancrage matériel obligatoire [86] contre opposabilité hors ligne [77] [80]	La part de parcs dotés d'une racine d'attestation
Multi-agents	Marge substantielle [96] [97] contre non-avantage à dix fois le prix [94] [95] [92]	Un protocole égalisant l'effort de réglage des deux bras [93]
Évaluation	Juge automatique : fiabilité quasi humaine [110] contre plafond démontré [109]	Un juge indépendant du banc, sur étiquettes humaines
Transactionnel	Collusion stable sous auto-optimisation [121] ou artefact d'homogénéité [120]	La population effective de modèles tarificateurs

Front	Désaccord	Ce qui l'arbitrerait
Processus	Suspendre l'effet jusqu'à certitude [126] [127] ou l'émettre et le réviser [129]	La part d'actions irréversibles dans un flux réel
Gouvernance	RIA opérationnalisable [138] ou structurellement inadéquat [139] ? Prémisses d'autonomie contestée [147] [148]	Confronter les champs d'un message aux articles 12, 14 et 26
Web agentique	Identification coopérative [149] [150] ou détection imposée [151] [152]	Le taux de conformité d'agents non coopératifs

14 Trois énoncés de la veille mis à l'épreuve

14.1 1. « Au-delà de deux sauts de délégation, aucun mécanisme normalisé ne maintient de traçabilité opposable. »

L'énoncé confond trois choses et se disloque dès qu'on les sépare.

Proposer est dépassé. HDP construit une chaîne append-only où *chaque* saut est signé, vérifiable hors ligne à la seule clé publique de l'émetteur, sans borne de profondeur, et se porte en Internet-Draft IETF [77] ; AIP fait porter la délégation multi-sauts par des jetons de capacité liés à l'invocation [16]. « Aucun mécanisme » est faux au sens littéral.

Prouver est nuancé, et c'est là que le champ a avancé. Une vérification mécanique en TLA+ sur 2,7 M d'états établit, pour une chaîne de profondeur arbitraire, le rétrécissement d'autorité, la restructurabilité forensique et le confinement de cascade — mais démontre que la préservation d'intention est *pratiquement infaisable* de façon déterministe [76]. Autrement dit : **on prouve ce qui fut fait sous quelle autorité, non que cela servait le mandat.** Ni l'atténuation récursive prouvée [83] ni la borne de propagation de responsabilité [78] ne déplacent ce partage.

Normaliser et adopter tient, et se durcit. La vérification formelle des spécifications relève 35 lacunes et 30 défaillances nées de la seule composition, et surtout qu'*aucun protocole n'assigne l'application inter-protocoles* [85] — or franchir plus de deux sauts en entreprise, c'est traverser des protocoles. Le socle d'authentification à un saut n'étant pas tenu [81], discuter du troisième est prématuré. **L'obstacle est de normalisation et d'instrumentation, non d'invention.**

14.2 2. « L'arrimage entre la couche d'orchestration installée et la pile agentique est unilatéral. »

Exact sur le déploiement, faux sur la littérature. Aucun protocole d'agents déployé n'a intégré de sémantique de processus, et le mouvement dominant descend du processus vers l'agent, enveloppant le moteur déterministe qui garde l'autorité d'exécution [132]. Mais la recherche propose depuis fin 2024 au moins quatre formalismes de processus conçus *pour* les

agents : un BPMN dont le métamodèle reçoit des constructions natives d’agent autonome [133] ; un graphe DCR qui encode les obligations légales et *pilote* le dialogue, le modèle réduit à une interface bornée [137] ; un langage dédié où frontières de responsabilité et portes d’approbation deviennent des invariants applicables [134] ; des modèles typés promus composants architecturaux de l’agent [131]. **Ce qui manque est l’adoption, non la proposition : la dissymétrie est industrielle, pas scientifique.**

14.3 3. « Aucun attribut du socle d’observabilité agentique ne décrit une chaîne de mandat ou de délégation. »

Confirmé par une seconde voie, et plus sévèrement. Un travail indépendant juge journaux d’audit, schémas OCSF et OpenTelemetry sémantiquement insuffisants pour reconstruire la propagation d’autorité, et va au-delà du décompte d’attributs : des traces identiques sont compatibles avec plusieurs assignations de mandat incompatibles, donc l’exécution déléguée n’est pas *identifiable* [84]. Surtout, la seule pièce arbitrée du front étend le modèle de provenance du W3C aux flux agentiques **sans jamais instancier actedOnBehalfOf** : elle relie les agents par `wasAssociatedWith`, attribue les données par `wasAttributedTo`, chaîne les invocations par `wasInformedBy` [112]. *L’absence n’est donc pas propre à un dépôt de conventions d’instrumentation : le modèle académique le plus normatif renonce lui aussi à la primitive que son standard lui offrait.*

15 Lacunes et programme de recherche

Deux manques dominant, parce qu’ils se recoupent sur tous les fronts.

Il n’existe aucun taux de base. Les échantillons se comptent en serveurs (64 611 ; 7 973), en outils (12 230 ; 353), en cas de test (1 356 ; 560), en dépôts (2 297), en marchés simulés (100) — **jamais en organisations, en déploiements ni en incidents observés.** Questions testables : quelle fraction des agents en service subit une tentative d’injection sur une période donnée, et avec quel taux d’aboutissement ? Quel est le taux de contestation d’une transaction agentique et sa répartition entre émetteur, acquéreur, marchand et fournisseur d’agent — question dont le front transactionnel n’offre pas une pièce [114] [115] ?

Personne ne mesure une propriété de bout en bout sur un système traversant deux protocoles distincts en déploiement réel. Toutes les mesures d’écosystème portent sur MCP seul ; la seule comparaison implémentée est un scénario unique dont les auteurs récusent la généralisation [57] ; la seule interopération hétérogène publiée ne rapporte aucun taux d’échec [61] ; les 30 propriétés temporelles d’un modèle unifiant MCP et A2A n’ont été vérifiées sur aucun déploiement [60]. Question testable : pour une tâche A2A → MCP en exploitation, quels sont taux d’échec, latence ajoutée et perte sémantique, sur un corpus reproductible ?

Quatre lacunes dérivées se formulent aussi. *Compensation* : que deviennent écritures, paiements et sous-délégations déjà émis quand un saut amont est invalidé après coup [75] [80] [87], si l’ensemble à compenser n’est pas calculable [84] ? *Trace comme preuve* : un tiers peut-il reconstruire d’une trace qui a mandaté quoi — critère de réussite d’aucun banc [113] ? *Conformité* : quels fitness et précision pour une trace d’agent alignée contre un modèle de processus [130] [136] ? *Invariance* : quel niveau d’autonomie survit à l’auto-modification, certificats [155] [156] et surfaces d’attaque de l’auto-évolution [154] portant sur le même échafaudage ?

16 Limites de cette revue

Ce n'est pas une revue systématique au sens PRISMA : ni protocole enregistré, ni critères d'inclusion figés avant collecte, ni double codage. L'interrogation porte sur arXiv, notices vérifiées une à une : ACM DL, IEEE Xplore, SpringerLink et la littérature grise restent hors champ, et le biais anglophone est entier. Aucune réplcation n'a été conduite : les chiffres sont ceux des auteurs, y compris là où la revue signale que l'instrument qui les produit est contesté. Le classement d'un artefact comme « construction des auteurs » relève d'un jugement de lecture ; son critère est publié pour être réfutable. La revue hérite enfin de la faiblesse qu'elle mesure : **76 % de son corpus ne présente aucun signe de revue par les pairs** et 58 % a été déposé en 2026. Auto-citation déclarée : la veille dont trois énoncés sont ici mis à l'épreuve est du même auteur.

17 Conclusion

Le meilleur résultat de cette revue n'est pas un fait du champ, mais une propriété du champ. Une littérature dont les trois quarts n'ont franchi aucun comité, dont la moitié évalue une construction de ses propres auteurs, et dont trois fronts indépendants concluent que l'instrument de mesure est faux, ne peut pas encore arbitrer une décision d'architecture. Elle peut seulement dire où regarder — et sur les trois énoncés soumis, elle l'a fait : deux déficits d'invention étaient des déficits d'adoption, le troisième est plus profond qu'annoncé.

Annexe : le corpus arbitré, et ce qu'il ne couvre pas

Un lecteur qui refuserait de s'appuyer sur autre chose qu'une publication établie disposerait des douze pièces ci-dessous, et de rien d'autre. Elles sont données ici avec la référence qui les atteste, relevée sur la notice du dépôt le 9 août 2026 — champ `journal_ref` pour les sept premières, champ DOI pour les cinq suivantes.

Tableau 8. – Les douze pièces du corpus dont la publication est attestée en notice, avec leur apport propre.

Réf.	Publication attestée	Apport
[4]	<i>IEEE Trans. on Cognitive Communications and Networking</i>	Pose l'« Internet des agents » comme objet d'architecture et en énumère les couches manquantes
[15]	ICAART 2026	Applique identifiants décentralisés et justificatifs vérifiables du W3C à des agents
[37]	<i>Künstliche Intelligenz</i> , 2024	Formule la vision des grands modèles de processus, d'où descend le front des processus d'affaires
[38]	Actes PMAI 25 (CEUR, vol. 4087)	Découvre la variabilité comportementale d'agents par

Réf.	Publication attestée	Apport
		fouille de processus sur leurs traces
[44]	Actes FAccT 2026	Établit que les agents de langue n’ont pas l’ancrage requis par un mécanisme de réputation
[46]	Actes ICML 2024	Propose l’échelle d’autonomie la plus citée du champ, et la seule opérationnalisable
[59]	Actes MSR “26	Constitue le seul jeu de données validé d’implémentations MCP — 2 297 dépôts, précision de 83 %
[136]	<i>Information Systems</i> , vol. 142, art. 102761	Mesure la compétence réelle des modèles à produire des modèles de processus valides
[142]	Actes REALM @ ACL 2025	Instruit la responsabilité par la relation de mandat, et non par l’autonomie du système
[143]	<i>European Journal of Risk Regulation</i> 16	Établit que le règlement européen alloue une responsabilité de supervision sans base empirique
[144]	Actes FAccT 2026	Documente les caractéristiques techniques et de sûreté d’agents effectivement déployés
[158]	Actes ACM, 2026	Mesure l’écart entre capacité annoncée et capacité réalisée — 102 agents, 31 participants

Ce que cette liste montre par ce qui n’y figure pas. Six des douze appartiennent au socle hérité de la veille et sont, pour quatre d’entre elles, antérieures à 2025. Des cent huit pièces versées par la passe de recherche neuve, **cinq seulement** portent une attestation : une au front des protocoles [59], une aux processus d’affaires [136], trois à la gouvernance [142], [143], [144] et une à l’horizon [158].

Cinq fronts n’en comptent aucune — la sécurité, l’identité et la délégation, les systèmes multi-agents, l’évaluation, la couche transactionnelle. Or ce sont exactement ceux qui portent

les énoncés les plus conséquents de cette revue : que les scores de défense ne survivent pas à l’adversaire adaptatif, que l’autorité doive s’atténuer à chaque saut, que le rendement du multi-agent soit non monotone, que le score publié ne soit pas ce qui s’observe, que le mandat signé ne soit pas le point de rupture. *Aucun de ces cinq résultats ne repose, à ce jour, sur une seule pièce dont un comité ait attesté la publication.*

Il ne s’ensuit pas qu’ils soient faux : plusieurs sont adossés à des mesures de grande taille que rien d’autre ne fournit, et la revue par les pairs n’est pas le seul régime de preuve concevable. Il s’ensuit que **le champ produit ses résultats les plus décisifs là où son appareil de contrôle est le plus faible**, et qu’un architecte qui s’y appuie le fait sous sa propre responsabilité. C’est le constat le plus utile que cette revue puisse rendre, et il ne se lit ni dans les résumés ni dans les comptes de citations : il fallait ouvrir les cent cinquante-huit notices pour l’obtenir.

Références

Chaque entrée porte le régime de publication relevé sur la notice du dépôt le 9 août 2026 : la référence de revue ou d’actes lorsqu’elle y figure, la mention d’une acceptation autodéclarée au seul champ de commentaire lorsqu’il n’y a que cela, et la qualification de prépublication non révisée par les pairs à défaut.

1. Abul Ehtesham, Aditi Singh *et al.*. « A survey of agent interoperability protocols: Model Context Protocol (MCP), Agent Communication Protocol (ACP), Agent-to-Agent Protocol (A2A), and Agent Network Protocol (ANP) ». arXiv:2505.02279v2, déposée le 4 mai 2025, v2 du 23 mai 2025 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2505.02279>
2. Yingxuan Yang, Huacan Chai *et al.*. « A Survey of AI Agent Protocols ». arXiv:2504.16736v3, déposée le 23 avril 2025, v3 du 21 juin 2025 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2504.16736>
3. Dezhang Kong, Shi Lin *et al.*. « A Survey of LLM-Driven AI Agent Communication: Protocols, Security Risks, and Defense Countermeasures ». arXiv:2506.19676v4, déposée le 24 juin 2025, v4 du 27 novembre 2025 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2506.19676>
4. Yuntao Wang, Shaolong Guo *et al.*. « Internet of Agents: Fundamentals, Applications, and Challenges ». arXiv:2505.07176v2, déposée le 12 mai 2025, v2 du 16 octobre 2025 — **publication attestée en notice**, doi:10.1109/TCCN.2025.3623369. <https://arxiv.org/abs/2505.07176>
5. Xinyi Hou, Yanjie Zhao *et al.*. « Model Context Protocol (MCP): Landscape, Security Threats, and Future Research Directions ». arXiv:2503.23278v3, déposée le 30 mars 2025, v3 du 7 octobre 2025 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2503.23278>
6. Mohammed Mehedi Hasan, Hao Li *et al.*. « Model Context Protocol (MCP) at First Glance: Studying the Security and Maintainability of MCP Servers ». arXiv:2506.13538v5, déposée le 16 juin 2025, v5 du 13 avril 2026 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2506.13538>

7. Xiaofan Li et Xing Gao. « A First Look at the Security Issues in the Model Context Protocol Ecosystem ». arXiv:2510.16558v2, déposée le 18 octobre 2025, v2 du 27 avril 2026 — acceptation annoncée au seul champ *Comments* (« This paper has been accepted to DSN 2026. The title has »), non confirmée en notice. <https://arxiv.org/abs/2510.16558>
8. Kehui Chen, Yicheng Sun *et al.*. « Understanding How Enterprises Adopt the Model Context Protocol for LLM-Driven Software Engineering ». arXiv:2606.09182v1, déposée le 8 juin 2026 — acceptation annoncée au seul champ *Comments* (« 12pages, preliminary version accepted at the 26th Inter »), non confirmée en notice. <https://arxiv.org/abs/2606.09182>
9. Idan Habler, Ken Huang *et al.*. « Building A Secure Agentic AI Application Leveraging A2A Protocol ». arXiv:2504.16902v2, déposée le 23 avril 2025, v2 du 2 mai 2025 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2504.16902>
10. Gaowei Chang, Eidan Lin *et al.*. « Agent Network Protocol Technical White Paper ». arXiv:2508.00007v1, déposée le 18 juillet 2025 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2508.00007>
11. Zeynab Anbiaee, Mahdi Rabbani *et al.*. « Security Threat Modeling for Emerging AI-Agent Protocols: A Comparative Analysis of MCP, A2A, Agora, and ANP ». arXiv:2602.11327v2, déposée le 11 février 2026, v2 du 17 avril 2026 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2602.11327>
12. Ken Huang, Vineeth Sai Narajala *et al.*. « A Novel Zero-Trust Identity Framework for Agentic AI: Decentralized Authentication and Fine-Grained Access Control ». arXiv:2505.19301v2, déposée le 25 mai 2025, v2 du 28 mai 2025 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2505.19301>
13. Subramanya Nagabhushanaradhya. « OpenID Connect for Agents (OIDC-A) 1.0: A Standard Extension for LLM-Based Agent Identity and Authorization ». arXiv:2509.25974v1, déposée le 30 septembre 2025 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2509.25974>
14. Abhishek Goswami. « Agentic JWT: A Secure Delegation Protocol for Autonomous AI Agents ». arXiv:2509.13597v1, déposée le 16 septembre 2025 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2509.13597>
15. Sandro Rodriguez Garzon, Awid Vaziry *et al.*. « AI Agents with Decentralized Identifiers and Verifiable Credentials ». arXiv:2511.02841v2, déposée le 1 octobre 2025, v2 du 15 décembre 2025 — **18th International Conference on Agents and Artificial Intelligence (ICAART), 2026, volume 1, pp. 252-259**, doi:10.5220/0014234400004052. <https://arxiv.org/abs/2511.02841>
16. Sunil Prakash. « AIP: Agent Identity Protocol for Verifiable Delegation Across MCP and A2A ». arXiv:2603.24775v1, déposée le 25 mars 2026 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2603.24775>
17. Ken Huang, Vineeth Sai Narajala *et al.*. « Agent Name Service (ANS): A Universal Directory for Secure AI Agent Discovery and Interoperability ». arXiv:2505.10609v1, déposée le 15 mai 2025 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2505.10609>

18. Kunlun Zhu, Hongyi Du *et al.*. « MultiAgentBench: Evaluating the Collaboration and Competition of LLM agents ». arXiv:2503.01935v1, déposée le 3 mars 2025 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2503.01935>
19. Asaf Yehudai, Lilach Eden *et al.*. « Survey on Evaluation of LLM-based Agents ». arXiv:2503.16416v2, déposée le 20 mars 2025, v2 du 23 avril 2026 — acceptation annoncée au seul champ *Comments* (« ACL Findings »), non confirmée en notice. <https://arxiv.org/abs/2503.16416>
20. Shaina Raza, Ranjan Sapkota *et al.*. « TRiSM for Agentic AI: A Review of Trust, Risk, and Security Management in LLM-based Agentic Multi-Agent Systems ». arXiv:2506.04133v5, déposée le 4 juin 2025, v5 du 18 décembre 2025 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2506.04133>
21. Richard Kang et Yudho Diponegoro. « Governance Gaps in Agent Interoperability Protocols: What MCP, A2A, and ACP Cannot Express ». arXiv:2606.31498v1, déposée le 30 juin 2026 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2606.31498>
22. Juan A. Wibowo et George C. Polyzos. « Toward a Safe Internet of Agents ». arXiv:2512.00520v2, déposée le 29 novembre 2025, v2 du 27 avril 2026 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2512.00520>
23. Grégoire Mialon, Clémentine Fourrier *et al.*. « GAIA: a benchmark for General AI Assistants ». arXiv:2311.12983v1, déposée le 21 novembre 2023 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2311.12983>
24. Shunyu Yao, Noah Shinn *et al.*. « τ -bench: A Benchmark for Tool-Agent-User Interaction in Real-World Domains ». arXiv:2406.12045v1, déposée le 17 juin 2024 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2406.12045>
25. Erik Pautsch, Tanmay Singla *et al.*. « AgentHub: A Registry for Discoverable, Verifiable, and Reproducible AI Agents ». arXiv:2510.03495v2, déposée le 3 octobre 2025, v2 du 26 février 2026 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2510.03495>
26. Georgios Ioannides, Christos Constantinou *et al.*. « MOD-X: A Modular Open Decentralized eXchange Framework proposal for Heterogeneous Interoperable Artificial Intelligence Agents ». arXiv:2507.04376v2, déposée le 6 juillet 2025, v2 du 8 juillet 2025 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2507.04376>
27. Roland R. Rodriguez. « Agent Identity URI Scheme: Topology-Independent Naming and Capability-Based Discovery for Multi-Agent Systems ». arXiv:2601.14567v2, déposée le 21 janvier 2026, v2 du 13 juillet 2026 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2601.14567>
28. Tatiana Petrova, Boris Bliznioukov *et al.*. « From Multi-Agent Systems and the Semantic Web to Agentic AI: A Unified Narrative of the Web of Agents ». arXiv:2507.10644v4, déposée le 14 juillet 2025, v4 du 24 mai 2026 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2507.10644>
29. Takumi Otsuka, Kentaroh Toyoda *et al.*. « AI Identity: Standards, Gaps, and Research Directions for AI Agents ». arXiv:2604.23280v1, déposée le 25 avril 2026 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2604.23280>

30. Krti Tallam. « Authorization Propagation in Multi-Agent AI Systems: Identity Governance as Infrastructure ». arXiv:2605.05440v1, déposée le 6 mai 2026 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2605.05440>
31. Maxim Vidgof, Stefan Bachhofner *et al.*. « Large Language Models for Business Process Management: Opportunities and Challenges ». arXiv:2304.04309v1, déposée le 9 avril 2023 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2304.04309>
32. Hoang Vu, Nataliia Klievtsova *et al.*. « Agentic Business Process Management: Practitioner Perspectives on Agent Governance in Business Processes ». arXiv:2504.03693v2, déposée le 23 mars 2025, v2 du 3 juillet 2025 — acceptation annoncée au seul champ *Comments* (« Accepted for Responsible BPM 2025, 15 pages including r »), non confirmée en notice. <https://arxiv.org/abs/2504.03693>
33. Marlon Dumas, Fredrik Milani *et al.*. « Agentic Business Process Management Systems ». arXiv:2601.18833v1, déposée le 25 janvier 2026 — acceptation annoncée au seul champ *Comments* (« Presented at the BPM'2025 conference on Artificial Inte »), non confirmée en notice. <https://arxiv.org/abs/2601.18833>
34. Diego Calvanese, Angelo Casciani *et al.*. « Agentic Business Process Management: A Research Manifesto ». arXiv:2603.18916v3, déposée le 19 mars 2026, v3 du 12 avril 2026 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2603.18916>
35. Tianbao Xie, Danyang Zhang *et al.*. « OSWorld: Benchmarking Multimodal Agents for Open-Ended Tasks in Real Computer Environments ». arXiv:2404.07972v2, déposée le 11 avril 2024, v2 du 30 mai 2024 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2404.07972>
36. Shangeetha Sivasothy, Scott Barnett *et al.*. « Large language models for generating rules, yay or nay? ». arXiv:2406.06835v1, déposée le 10 juin 2024 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2406.06835>
37. Timotheus Kampik, Christian Warmuth *et al.*. « Large Process Models: A Vision for Business Process Management in the Age of Generative AI ». arXiv:2309.00900v3, déposée le 2 septembre 2023, v3 du 17 janvier 2025 — **Künstl Intell (2024)**, doi:10.1007/s13218-024-00863-8. <https://arxiv.org/abs/2309.00900>
38. Fabiana Fournier, Lior Limonad *et al.*. « Agentic AI Process Observability: Discovering Behavioral Variability ». arXiv:2505.20127v2, déposée le 26 mai 2025, v2 du 3 juillet 2025 — **PMAI 25 (CEUR proceedings); Vol 4087; 2025**. <https://arxiv.org/abs/2505.20127>
39. Alessandro Berti, Humam Kourani *et al.*. « PM-LLM-Benchmark: Evaluating Large Language Models on Process Mining Tasks ». arXiv:2407.13244v1, déposée le 18 juillet 2024 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2407.13244>
40. Yingxuan Yang, Mulei Ma *et al.*. « Agentic Web: Weaving the Next Web with AI Agents ». arXiv:2507.21206v1, déposée le 28 juillet 2025 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2507.21206>
41. Cameron Pattison, Matthew Boulos *et al.*. « The Agentic Web Requires New Normative Infrastructure ». arXiv:2606.10711v2, déposée le 9 juin 2026, v2 du 15 juillet 2026 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2606.10711>
42. Yuhan Jin, Shuohan Wu *et al.*. « The Web4 Agent Economy: A Large-Scale Empirical Study of the Landscape, Challenges, and Opportunities ». arXiv:2606.25876v1, déposée

- le 24 juin 2026 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2606.25876>
43. Shengchen Ling, Yihang Huang *et al.*. « Free-Riding the Agentic Web: A Systematic Security Analysis of x402 Payments ». arXiv:2605.30998v2, déposée le 29 mai 2026, v2 du 22 juin 2026 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2605.30998>
 44. Botao Amber Hu, Helena Rong *et al.*. « Dissociative Identity: Language Model Agents Lack Grounding for Reputation Mechanisms ». arXiv:2605.30169v3, déposée le 28 mai 2026, v3 du 2 juillet 2026 — **publication attestée en notice**, doi:10.1145/3805689.3806748. <https://arxiv.org/abs/2605.30169>
 45. Cristian Trout, Sanmi Koyejo *et al.*. « Underwriting the Agent Economy: The Blueprint for an AI Insurance Stack ». arXiv:2607.11999v2, déposée le 13 juillet 2026, v2 du 15 juillet 2026 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2607.11999>
 46. Meredith Ringel Morris, Jascha Sohl-Dickstein *et al.*. « Levels of AGI for Operationalizing Progress on the Path to AGI ». arXiv:2311.02462v5, déposée le 4 novembre 2023, v5 du 24 septembre 2025 — **Proceedings of ICML 2024**. <https://arxiv.org/abs/2311.02462>
 47. Zelin Li, Qin Wang *et al.*. « Five Attacks on x402 Agentic Payment Protocol ». arXiv:2605.11781v1, déposée le 12 mai 2026 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2605.11781>
 48. Mert Cemri, Melissa Z. Pan *et al.*. « Why Do Multi-Agent LLM Systems Fail? ». arXiv:2503.13657v3, déposée le 17 mars 2025, v3 du 26 octobre 2025 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2503.13657>
 49. Nicolás Padilla. « Exposed by Design: A Dynamic Security Assessment of Internet-Facing MCP Servers at Scale ». arXiv:2608.00150v1, déposée le 31 juillet 2026 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2608.00150>
 50. Xuanze Chen, Xukang Xie *et al.*. « MemSecBench: Tracking Agent Memory Poisoning from Persistence to Consequence and Repair ». arXiv:2607.27080v1, déposée le 29 juillet 2026 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2607.27080>
 51. Pei Chen, Baichao An *et al.*. « Rethinking MCP Security: A Large-Scale Study of Runtime MCP Servers and Security Scanner Reliability ». arXiv:2607.11086v1, déposée le 13 juillet 2026 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2607.11086>
 52. Mengying Wu, Pei Chen *et al.*. « MCPZoo: A Large-Scale Dataset of Runnable Model Context Protocol Servers for AI Agent ». arXiv:2512.15144v3, déposée le 17 décembre 2025, v3 du 26 décembre 2025 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2512.15144>
 53. Mohammed Mehedi Hasan, Hao Li *et al.*. « Model Context Protocol (MCP) Tool Descriptions Are Smelly! Towards Improving AI Agent Efficiency with Augmented MCP Tool Descriptions ». arXiv:2602.14878v3, déposée le 16 février 2026, v3 du 31 mai 2026 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2602.14878>
 54. Muhammad Hamza Arshad Majeed, May Mahmoud *et al.*. « An Empirical Study of Model Context Protocol Applications ». arXiv:2607.25635v2, déposée le 28 juillet 2026, v2 du 29 juillet 2026 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2607.25635>

55. Yutao Shi, Xiaohan Zhang *et al.*. « Description-Code Inconsistency in Real-world MCP Servers: Measurement, Detection, and Security Implications ». arXiv:2606.04769v1, déposée le 3 juin 2026 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2606.04769>
56. Andreas Schlapbach. « Formal Semantics for Agentic Tool Protocols: A Process Calculus Approach ». arXiv:2603.24747v3, déposée le 25 mars 2026, v3 du 2 juillet 2026 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2603.24747>
57. Ionut Predoaia, Tuong Manh Vu *et al.*. « A Comparative Study of MCP and A2A for Inter-Agent Coordination in LLM-Based Systems ». arXiv:2607.23884v1, déposée le 26 juillet 2026 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2607.23884>
58. Gautam Bharti. « Registry Descriptions Go Stale Unevenly: An 89-Day Measurement of Model Context Protocol Drift, and Why Drift-Ranked Re-Auditing Under-Covers It ». arXiv:2608.00997v2, déposée le 2 août 2026, v2 du 4 août 2026 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2608.00997>
59. Benny Toeppe, Amine Barrak *et al.*. « A Large-Scale Dataset of MCP Implementations on GitHub ». arXiv:2607.10123v1, déposée le 11 juillet 2026 — **Proceedings of MSR “26: 23rd International Conference on Mining Software Repositories, April 13-14, 2026, Rio de Janeiro, Brazil. ACM, 2026**. <https://arxiv.org/abs/2607.10123>
60. Edoardo Allegrini, Ananth Shreekumar *et al.*. « Formalizing the Safety, Security, and Functional Properties of Agentic AI Systems ». arXiv:2510.14133v2, déposée le 15 octobre 2025, v2 du 15 avril 2026 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2510.14133>
61. Samuel H. Christie, Amit K. Chopra *et al.*. « Strabo: Declarative Specification and Implementation of Agentic Interaction Protocols ». arXiv:2606.05043v1, déposée le 3 juin 2026 — acceptation annoncée au seul champ *Comments* (« Presented in the Engineering Multiagent Systems Worksho »), non confirmée en notice. <https://arxiv.org/abs/2606.05043>
62. Dun Yuan, Fuyuan Lyu *et al.*. « Beyond Message Passing: A Semantic View of Agent Communication Protocols ». arXiv:2604.02369v3, déposée le 30 mars 2026, v3 du 13 avril 2026 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2604.02369>
63. Mugeng Liu, Shuoqi Li *et al.*. « Beyond Static Endpoints: Tool Programs as an Interface for Flexible Agentic Web Services ». arXiv:2606.19992v1, déposée le 18 juin 2026 — acceptation annoncée au seul champ *Comments* (« Accepted by ICML 2026 »), non confirmée en notice. <https://arxiv.org/abs/2606.19992>
64. Woohyuk Choi, Juhee Kim *et al.*. « Agent Data Injection Attacks are Realistic Threats to AI Agents ». arXiv:2607.05120v1, déposée le 6 juillet 2026 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2607.05120>
65. Ben Nassi, Stav Cohen *et al.*. « Invitation Is All You Need! Promptware Attacks Against LLM-Powered Assistants in Production Are Practical and Dangerous ». arXiv:2508.12175v1, déposée le 16 août 2025 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2508.12175>
66. Shuli Zhao, Qinsheng Hou *et al.*. « Parasites in the Toolchain: A Large-Scale Analysis of Attacks on the MCP Ecosystem ». arXiv:2509.06572v5, déposée le 8 septembre 2025, v5 du 1 mai 2026 — acceptation annoncée au seul champ *Comments* (« Accepted by IEEE

- Symposium on Security and Privacy, 202 »), non confirmée en notice. <https://arxiv.org/abs/2509.06572>
67. Zhiqiang Wang, Yichao Gao *et al.*. « MCPTox: A Benchmark for Tool Poisoning Attack on Real-World MCP Servers ». arXiv:2508.14925v1, déposée le 19 août 2025 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2508.14925>
 68. David Schmotz, Luca Beurer-Kellner *et al.*. « Skill-Inject: Measuring Agent Vulnerability to Skill File Attacks ». arXiv:2602.20156v3, déposée le 23 février 2026, v3 du 25 février 2026 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2602.20156>
 69. Hengyu An, Minxi Li *et al.*. « ACIArena: Toward Unified Evaluation for Agent Cascading Injection ». arXiv:2604.07775v1, déposée le 9 avril 2026 — acceptation annoncée au seul champ *Comments* (« ACL 2026 »), non confirmée en notice. <https://arxiv.org/abs/2604.07775>
 70. Debeshee Das, Julien Piet *et al.*. « Trojan Hippo: Weaponizing Agent Memory for Data Exfiltration ». arXiv:2605.01970v3, déposée le 3 mai 2026, v3 du 15 mai 2026 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2605.01970>
 71. Xinhang Ma, Taoran Li *et al.*. « AutoDojo: Adaptive Black-Box Attacks Reveal the Limits of IPI Defenses and Task-Specification Effects in LLM Agents ». arXiv:2606.15057v2, déposée le 13 juin 2026, v2 du 19 juin 2026 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2606.15057>
 72. Hao Li, Ruoyao Wen *et al.*. « AgentDyn: Are Your Agent Security Defenses Deployable in Real-World Dynamic Environments? ». arXiv:2602.03117v3, déposée le 3 février 2026, v3 du 7 mai 2026 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2602.03117>
 73. Zixin Rao, Wentian Zhu *et al.*. « FragFuse: Bypassing Access Control of Large Language Model Agents via Memory-Based Query Fragmentation and Fusion ». arXiv:2606.15609v1, déposée le 14 juin 2026 — acceptation annoncée au seul champ *Comments* (« 33 pages, 4 figures. Accepted by USENIX Security 2026 »), non confirmée en notice. <https://arxiv.org/abs/2606.15609>
 74. Dennis Jacob, Emad Alghamdi *et al.*. « Preventing Prompt Injection with Type-Directed Privilege Separation ». arXiv:2509.25926v2, déposée le 30 septembre 2025, v2 du 8 mai 2026 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2509.25926>
 75. Vladyslav Parakhin. « The Bureaucracy of Speed: Structural Equivalence Between Memory Consistency Models and Multi-Agent Authorization Revocation ». arXiv:2603.09875v1, déposée le 10 mars 2026 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2603.09875>
 76. KrishnaSaiReddy Patil. « SentinelAgent: Intent-Verified Delegation Chains for Securing Federal Multi-Agent AI Systems ». arXiv:2604.02767v1, déposée le 3 avril 2026 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2604.02767>
 77. Asiri Dalugoda. « HDP: A Lightweight Cryptographic Protocol for Human Delegation Provenance in Agentic AI Systems ». arXiv:2604.04522v1, déposée le 6 avril 2026 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2604.04522>
 78. Yuan Sun. « Safe Bilevel Delegation (SBD): A Formal Framework for Runtime Delegation Safety in Multi-Agent Systems ». arXiv:2604.27358v1, déposée le 30 avril 2026 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2604.27358>

79. Mehmet Haklidor. « Consent Chain Degradation in Embodied Multi-Agent Systems: Bridging the Gap Between AI Agent Governance and Robot Ethics ». arXiv:2605.16300v1, déposée le 17 avril 2026 — acceptation annoncée au seul champ *Comments* (« Accepted for oral presentation at the 2nd Workshop on R »), non confirmée en notice. <https://arxiv.org/abs/2605.16300>
80. Saurabh Deochake. « Heartbeat-Bound Hierarchical Credentials: Cryptographic Revocation for AI Agent Swarms ». arXiv:2605.20704v1, déposée le 20 mai 2026 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2605.20704>
81. Huijun Zhou, Xiaohan Zhang *et al.*. « A First Measurement Study on Authentication Security in Real-World Remote MCP Servers ». arXiv:2605.22333v1, déposée le 21 mai 2026 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2605.22333>
82. Christophe Parisel. « Privilege Risk Evolution for Non-Human Identities: A Temporal Fiber Model for Cloud IAM ». arXiv:2606.03289v1, déposée le 2 juin 2026 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2606.03289>
83. Amjad Ibrahim et Yong Li. « Overlaying Governance: A Compositional Authorization Framework for Delegation and Scope in Agentic AI ». arXiv:2606.03518v1, déposée le 2 juin 2026 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2606.03518>
84. Abhinav Mishra et Kumar Sharad. « Observability for Delegated Execution in Agentic AI Systems ». arXiv:2606.09692v1, déposée le 8 juin 2026 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2606.09692>
85. Shenghan Zheng, Qifan Zhang *et al.*. « Formal Security Analysis of Agent Protocol Composition ». arXiv:2606.28690v1, déposée le 27 juin 2026 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2606.28690>
86. Anton Sokolov. « Hardware-rooted attestation for AI-agent evidence: composing IETF RATS with action evidence packages ». arXiv:2608.00801v1, déposée le 1 août 2026 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2608.00801>
87. Igor Santos-Grueiro. « Lingering Authority: Revocable Resource-and-Effect Capabilities for Coding Agents ». arXiv:2606.22504v1, déposée le 21 juin 2026 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2606.22504>
88. Shaokun Zhang, Ming Yin *et al.*. « Which Agent Causes Task Failures and When? On Automated Failure Attribution of LLM Multi-Agent Systems ». arXiv:2505.00212v3, déposée le 30 avril 2025, v3 du 2 juin 2025 — acceptation annoncée au seul champ *Comments* (« camera-ready »), non confirmée en notice. <https://arxiv.org/abs/2505.00212>
89. Mengzhuo Chen, Junjie Wang *et al.*. « Seeing the Whole Elephant: A Benchmark for Failure Attribution in LLM-based Multi-Agent Systems ». arXiv:2604.22708v1, déposée le 24 avril 2026 — acceptation annoncée au seul champ *Comments* (« Accepted by ACL 2026 »), non confirmée en notice. <https://arxiv.org/abs/2604.22708>
90. Yizhe Xie, Congcong Zhu *et al.*. « From Spark to Fire: Modeling and Mitigating Error Cascades in LLM-Based Multi-Agent Collaboration ». arXiv:2603.04474v2, déposée le 4 mars 2026, v2 du 11 mai 2026 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2603.04474>
91. Maksym Nechepurenko et Pavel Shuvalov. « Coordination as an Architectural Layer for LLM-Based Multi-Agent Systems ». arXiv:2605.03310v1, déposée le 5 mai 2026 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2605.03310>

92. Qineng Wang, Zihao Wang *et al.*. « Rethinking the Bounds of LLM Reasoning: Are Multi-Agent Discussions the Key? ». arXiv:2402.18272v1, déposée le 28 février 2024 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2402.18272>
93. Andries Smit, Paul Duckworth *et al.*. « Should we be going MAD? A Look at Multi-Agent Debate Strategies for LLMs ». arXiv:2311.17371v3, déposée le 29 novembre 2023, v3 du 18 juillet 2024 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2311.17371>
94. Prathyusha Jwalapuram, Hehai Lin *et al.*. « The Illusion of Multi-Agent Advantage ». arXiv:2606.13003v2, déposée le 11 juin 2026, v2 du 13 juin 2026 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2606.13003>
95. Yuxuan Zhao, Sijia Chen *et al.*. « When Does Multi-Agent Collaboration Help? An Entropy Perspective ». arXiv:2602.04234v6, déposée le 4 février 2026, v6 du 4 juin 2026 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2602.04234>
96. Chen Qian, Zihao Xie *et al.*. « Scaling Large Language Model-based Multi-Agent Collaboration ». arXiv:2406.07155v3, déposée le 11 juin 2024, v3 du 17 mars 2025 — acceptation annoncée au seul champ *Comments* (« Accepted to ICLR-2025 »), non confirmée en notice. <https://arxiv.org/abs/2406.07155>
97. Han Zhou, Xingchen Wan *et al.*. « Multi-Agent Design: Optimizing Agents with Better Prompts and Topologies ». arXiv:2502.02533v2, déposée le 4 février 2025, v2 du 31 janvier 2026 — acceptation annoncée au seul champ *Comments* (« ICLR 2026 »), non confirmée en notice. <https://arxiv.org/abs/2502.02533>
98. Siddhant Kulkarni et Yukta Kulkarni. « Benchmarking Multi-Agent LLM Architectures for Financial Document Processing: A Comparative Study of Orchestration Patterns, Cost-Accuracy Tradeoffs and Production Scaling Strategies ». arXiv:2603.22651v1, déposée le 24 mars 2026 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2603.22651>
99. Fulin Lin, Shaowen Chen *et al.*. « Stop Wasting Your Tokens: Towards Efficient Runtime Multi-Agent Systems ». arXiv:2510.26585v2, déposée le 30 octobre 2025, v2 du 2 mars 2026 — acceptation annoncée au seul champ *Comments* (« Accepted to ICLR 2026. The code is available at <https://> »), non confirmée en notice. <https://arxiv.org/abs/2510.26585>
100. Yian Wang, Agam Goyal *et al.*. « State Contamination in Memory-Augmented LLM Agents ». arXiv:2605.16746v1, déposée le 16 mai 2026 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2605.16746>
101. Emre Turan. « Oversight Has a Capacity: Calibrating Agent Guards to a Subjective, Fatiguing Human ». arXiv:2606.08919v1, déposée le 8 juin 2026 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2606.08919>
102. Frank F. Xu, Yufan Song *et al.*. « TheAgentCompany: Benchmarking LLM Agents on Consequential Real World Tasks ». arXiv:2412.14161v3, déposée le 18 décembre 2024, v3 du 10 septembre 2025 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2412.14161>
103. Xingyao Wang, Boxuan Li *et al.*. « OpenHands: An Open Platform for AI Software Developers as Generalist Agents ». arXiv:2407.16741v3, déposée le 23 juillet 2024, v3 du 18 avril 2025 — acceptation annoncée au seul champ *Comments* (« Accepted by ICLR

- 2025; Code: <https://github.com/All-Han> »), non confirmée en notice. <https://arxiv.org/abs/2407.16741>
104. Kung-Hsiang Huang, Akshara Prabhakar *et al.*. « CRMArena-Pro: Holistic Assessment of LLM Agents Across Diverse Business Scenarios and Interactions ». arXiv:2505.18878v1, déposée le 24 mai 2025 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2505.18878>
 105. Yipeng Ouyang, Xin Huang *et al.*. « Benchmarks are Not Enough: RAMP for Runtime Assessing of Agentic Models in Production Systems ». arXiv:2605.27492v1, déposée le 26 mai 2026 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2605.27492>
 106. Sayash Kapoor, Benedikt Stroebl *et al.*. « AI Agents That Matter ». arXiv:2407.01502v1, déposée le 1 juillet 2024 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2407.01502>
 107. Yuxuan Zhu, Tengjun Jin *et al.*. « Establishing Best Practices for Building Rigorous Agentic Benchmarks ». arXiv:2507.02825v5, déposée le 3 juillet 2025, v5 du 7 août 2025 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2507.02825>
 108. Shanchao Liang, Spandan Garg *et al.*. « The SWE-Bench Illusion: When State-of-the-Art LLMs Remember Instead of Reason ». arXiv:2506.12286v4, déposée le 14 juin 2025, v4 du 1 décembre 2025 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2506.12286>
 109. Florian E. Dorner, Vivian Y. Nastl *et al.*. « Limits to scalable evaluation at the frontier: LLM as Judge won't beat twice the data ». arXiv:2410.13341v3, déposée le 17 octobre 2024, v3 du 6 janvier 2026 — acceptation annoncée au seul champ *Comments* (« ICLR 2025; 28 pages, 8 figures »), non confirmée en notice. <https://arxiv.org/abs/2410.13341>
 110. Mingchen Zhuge, Changsheng Zhao *et al.*. « Agent-as-a-Judge: Evaluate Agents with Agents ». arXiv:2410.10934v2, déposée le 14 octobre 2024, v2 du 16 octobre 2024 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2410.10934>
 111. Darshan Deshpande, Varun Gangal *et al.*. « TRAIL: Trace Reasoning and Agentic Issue Localization ». arXiv:2505.08638v3, déposée le 13 mai 2025, v3 du 23 juin 2025 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2505.08638>
 112. Renan Souza, Amal Gueroudji *et al.*. « PROV-AGENT: Unified Provenance for Tracking AI Agent Interactions in Agentic Workflows ». arXiv:2508.02866v3, déposée le 4 août 2025, v3 du 20 août 2025 — acceptation annoncée au seul champ *Comments* (« Paper accepted for publication in the Proceedings of th »), non confirmée en notice. <https://arxiv.org/abs/2508.02866>
 113. Yi Nian, Aojie Yuan *et al.*. « Auditable Agents ». arXiv:2604.05485v1, déposée le 7 avril 2026 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2604.05485>
 114. Qian'ang Mao, Jiaxin Wang *et al.*. « SoK: Security of Autonomous LLM Agents in Agentic Commerce ». arXiv:2604.15367v2, déposée le 15 avril 2026, v2 du 1 mai 2026 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2604.15367>
 115. Yuanzhe Zhang, Yuexin Xiang *et al.*. « SoK: Blockchain Agent-to-Agent Payments ». arXiv:2604.03733v1, déposée le 4 avril 2026 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2604.03733>

116. Tanusree Debi, Wentian Zhu *et al.*. « Whispers of Wealth: Red-Teaming Google’s Agent Payments Protocol via Prompt Injection ». arXiv:2601.22569v2, déposée le 30 janvier 2026, v2 du 18 mai 2026 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2601.22569>
117. Qianlong Lan, Anuj Kaul *et al.*. « Zero-Trust Runtime Verification for Agentic Payment Protocols: Mitigating Replay and Context-Binding Failures in AP2 ». arXiv:2602.06345v1, déposée le 6 février 2026 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2602.06345>
118. Xihan Xiong, Zelin Li *et al.*. « Can Trustless Agents Be Trusted? An Empirical Study of the ERC-8004 Decentralized AI Agent Ecosystem ». arXiv:2606.26028v2, déposée le 24 juin 2026, v2 du 8 juillet 2026 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2606.26028>
119. Sara Fish, Yannai A. Gonczarowski *et al.*. « Algorithmic Collusion by Large Language Models ». arXiv:2404.00806v5, déposée le 31 mars 2024, v5 du 5 mars 2026 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2404.00806>
120. Jussi Keppo, Yuze Li *et al.*. « On the Fragility of AI Agent Collusion ». arXiv:2603.20281v1, déposée le 18 mars 2026 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2603.20281>
121. Yingtao Tian. « Prompt Optimization Enables Stable Algorithmic Collusion in LLM Agents ». arXiv:2604.17774v1, déposée le 20 avril 2026 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2604.17774>
122. Gagan Bansal, Wenyue Hua *et al.*. « Magentic Marketplace: An Open-Source Environment for Studying Agentic Markets ». arXiv:2510.25779v1, déposée le 27 octobre 2025 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2510.25779>
123. Xianyang Liu, Shangding Gu *et al.*. « AgenticPay: A Multi-Agent LLM Negotiation System for Buyer-Seller Transactions ». arXiv:2602.06008v1, déposée le 5 février 2026 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2602.06008>
124. Amine Allouah, Omar Besbes *et al.*. « What Is Your AI Agent Buying? Evaluation, Biases, Model Dependence, & Emerging Implications for Agentic E-Commerce ». arXiv:2508.02630v3, déposée le 4 août 2025, v3 du 17 décembre 2025 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2508.02630>
125. Alexander Erlei et Lukas Meub. « LLM-Agent Interactions on Markets with Information Asymmetries ». arXiv:2603.08853v1, déposée le 9 mars 2026 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2603.08853>
126. Bardia Mohammadi, Nearchos Potamitis *et al.*. « Atomix: Timely, Transactional Tool Use for Reliable Agentic Workflows ». arXiv:2602.14849v2, déposée le 16 février 2026, v2 du 29 mai 2026 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2602.14849>
127. Edward Y. Chang, Longling Geng *et al.*. « Mnemosyne: Agentic Transaction Processing for Validating and Repairing AI-generated Workflows ». arXiv:2607.00269v2, déposée le 30 juin 2026, v2 du 5 juillet 2026 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2607.00269>

128. Sajjad Khan. « Verified Detection and Prevention of Concurrency Anomalies in Multi-Agent Large Language Model Systems ». arXiv:2606.17182v1, déposée le 15 juin 2026 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2606.17182>
129. Zhiyuan Zhai, Ming Li *et al.*. « Revisable by Design: A Theory of Streaming LLM Agent Execution ». arXiv:2604.23283v1, déposée le 25 avril 2026 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2604.23283>
130. Hoang Vu, Maximilian Körner *et al.*. « Agent Behavior Mining: Generative AI Agent Governance in Business Processes ». arXiv:2606.20669v1, déposée le 12 juin 2026 — acceptation annoncée au seul champ *Comments* (« Accepted at BPM conference 2026 management main track »), non confirmée en notice. <https://arxiv.org/abs/2606.20669>
131. Alexander Rombach, Chantale Lauer *et al.*. « Neuro-Symbolic Agents for Regulated Process Automation: Challenges and Research Agenda ». arXiv:2606.13405v2, déposée le 11 juin 2026, v2 du 22 juin 2026 — acceptation annoncée au seul champ *Comments* (« Accepted as a poster in NILA Workshop @ IJCAI-ECAI 2026 »), non confirmée en notice. <https://arxiv.org/abs/2606.13405>
132. Fabiana Fournier et Lior Limonad. « A Process Harness for Uplifting Legacy Workflows to Agentic BPM: Design and Realization in CUGA FLO ». arXiv:2606.27188v1, déposée le 25 juin 2026 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2606.27188>
133. Adem Ait, Javier Luis Cánovas Izquierdo *et al.*. « Towards Modeling Human-Agent Collaborative Workflows: A BPMN Extension ». arXiv:2412.05958v3, déposée le 8 décembre 2024, v3 du 27 juin 2025 — acceptation annoncée au seul champ *Comments* (« Accepted in the Euromicro Conference Series on Software »), non confirmée en notice. <https://arxiv.org/abs/2412.05958>
134. Ylli Prifti. « Specifying AI-SDLC Processes: A Protocol Language for Human-Agent Boundaries ». arXiv:2606.20615v2, déposée le 24 mai 2026, v2 du 24 juin 2026 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2606.20615>
135. Saimir Bala, Fabiana Fournier *et al.*. « Using Process Mining to Generate AI Agents from Software Engineering Process Records ». arXiv:2607.04948v1, déposée le 6 juillet 2026 — acceptation annoncée au seul champ *Comments* (« To be published at the 24th International Conference on »), non confirmée en notice. <https://arxiv.org/abs/2607.04948>
136. Chantale Lauer, Peter Pfeiffer *et al.*. « Assessing the Business Process Modeling Competences of Large Language Models ». arXiv:2601.21787v2, déposée le 29 janvier 2026, v2 du 29 juin 2026 — **Information Systems, Vol. 142 (2026), Art. 102761**, doi:10.1016/j.is.2026.102761. <https://arxiv.org/abs/2601.21787>
137. Ilias Chalkidis, Vlad Paul Cosma *et al.*. « Hybrid AI for Explainable and Accurate Conversational Agents in eGovernment ». arXiv:2608.01346v1, déposée le 2 août 2026 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2608.01346>
138. Luca Nannini, Adam Leon Smith *et al.*. « AI Agents Under EU Law ». arXiv:2604.04604v1, déposée le 6 avril 2026 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2604.04604>
139. Kathrin Gardhouse, Amin Oueslati *et al.*. « Regulating AI Agents ». arXiv:2603.23471v2, déposée le 24 mars 2026, v2 du 7 juillet 2026 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2603.23471>

140. Yiheng Yao. « Acting with AI: An Interaction-Based Framework for Agentic Tort Liability ». arXiv:2606.00518v1, déposée le 30 mai 2026 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2606.00518>
141. Mark O. Riedl et Deven R. Desai. « AI Agents and the Law ». arXiv:2508.08544v1, déposée le 12 août 2025 — acceptation annoncée au seul champ *Comments* (« 2025 AAAI Conference on AI, Ethics, and Society »), non confirmée en notice. <https://arxiv.org/abs/2508.08544>
142. Garry A. Gabison et R. Patrick Xian. « Inherent and emergent liability issues in LLM-based agentic systems: a principal-agent perspective ». arXiv:2504.03255v2, déposée le 4 avril 2025, v2 du 17 juin 2025 — **publication attestée en notice**, doi:10.18653/v1/2025.realm-1.9. <https://arxiv.org/abs/2504.03255>
143. Johann Laux et Hannah Ruschemeier. « Automation Bias in the AI Act: On the Legal Implications of Attempting to De-Bias Human Oversight of AI ». arXiv:2502.10036v2, déposée le 14 février 2025, v2 du 20 juin 2025 — **Eur. j. risk regul. 16 (2025) 1519-1534**, doi:10.1017/err.2025.10033. <https://arxiv.org/abs/2502.10036>
144. Leon Staufer, Kevin Feng *et al.*. « The 2025 AI Agent Index: Documenting Technical and Safety Features of Deployed Agentic AI Systems ». arXiv:2602.17753v2, déposée le 19 février 2026, v2 du 6 mai 2026 — **publication attestée en notice**, doi:10.1145/3805689.3806728. <https://arxiv.org/abs/2602.17753>
145. Mubarak Raji et Masooda Bashir. « Towards Agentic AI Governance: A Preliminary Assessment ». arXiv:2607.07612v1, déposée le 8 juillet 2026 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2607.07612>
146. Irene Aldridge et Steve Krawciw. « AI Governance for Institutional Readiness in Finance ». arXiv:2608.02311v1, déposée le 3 août 2026 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2608.02311>
147. Gabriela Aránguiz Dias, Kiana Jafari *et al.*. « The Doctor Will (Still) See You Now: On the Structural Limits of Agentic AI in Healthcare ». arXiv:2602.18460v1, déposée le 6 février 2026 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2602.18460>
148. Sebastian Lobentanzer. « Quantifying the Expectation-Realisation Gap for Agentic AI Systems ». arXiv:2602.20292v2, déposée le 23 février 2026, v2 du 25 février 2026 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2602.20292>
149. Eranga Bandara, Ross Gore *et al.*. « Towards an Agent-First Web: Redesigning the Web for AI Agents ». arXiv:2606.19116v1, déposée le 17 juin 2026 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2606.19116>
150. Sven Schultze, Meike Verena Kietzmann *et al.*. « Building the Web for Agents: A Declarative Framework for Agent-Web Interaction ». arXiv:2511.11287v1, déposée le 14 novembre 2025 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2511.11287>
151. Taein Kim, Karstan Bock *et al.*. « Scrapers selectively respect robots.txt directives: evidence from a large-scale empirical study ». arXiv:2505.21733v2, déposée le 27 mai 2025, v2 du 23 octobre 2025 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2505.21733>

152. Ethan Wang, Zubair Shafiq *et al.*. « FP-Agent: Fingerprinting AI Browsing Agents ». arXiv:2605.01247v1, déposée le 2 mai 2026 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2605.01247>
153. Zhe Ren, Yimeng Chen *et al.*. « Self-Improvements in Modern Agentic Systems: A Survey ». arXiv:2607.13104v1, déposée le 14 juillet 2026 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2607.13104>
154. Ruixiao Lin, Xinhao Deng *et al.*. « Safety in Self-Evolving LLM Agent Systems: Threats, Amplification, and Case Studies ». arXiv:2606.23075v1, déposée le 22 juin 2026 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2606.23075>
155. K. J. Kevin Feng, David W. McDonald *et al.*. « Levels of Autonomy for AI Agents ». arXiv:2506.12469v2, déposée le 14 juin 2025, v2 du 28 juillet 2025 — acceptation annoncée au seul champ *Comments* (« Published in the Knight 1st Amendment Institute’s « AI a »), non confirmée en notice. <https://arxiv.org/abs/2506.12469>
156. Peter Cihon, Merlin Stein *et al.*. « Measuring AI agent autonomy: Towards a scalable approach with code inspection ». arXiv:2502.15212v1, déposée le 21 février 2025 — acceptation annoncée au seul champ *Comments* (« NeurIPS Socially Responsible Language Modelling Research »), non confirmée en notice. <https://arxiv.org/abs/2502.15212>
157. Eric Xing, Mingkai Deng *et al.*. « Critique of Agent Model ». arXiv:2606.23991v1, déposée le 22 juin 2026 — **prépublication non révisée par les pairs**. <https://arxiv.org/abs/2606.23991>
158. Pradyumna Shome, Sashreek Krishnan *et al.*. « Why Johnny Can’t Use Agents: Industry Aspirations vs. User Realities with AI Agents ». arXiv:2509.14528v2, déposée le 18 septembre 2025, v2 du 3 mai 2026 — **publication attestée en notice**, doi:10.1145/3786335.3813140. <https://arxiv.org/abs/2509.14528>
159. Institut national des normes et de la technologie (NIST). « Artificial Intelligence Risk Management Framework (AI RMF 1.0) ». NIST AI 100-1, janvier 2023. <https://doi.org/10.6028/NIST.AI.100-1>
160. H. Garcia-Molina et K. Salem. « Sagas ». *ACM SIGMOD Record*, vol. 16, n° 3, 1987, p. 249-259 — **actes SIGMOD 1987**. <https://doi.org/10.1145/38714.38742>
161. S. Burckhardt, C. Gillum, D. Justo *et al.*. « Durable Functions: Semantics for Stateful Serverless ». *Proceedings of the ACM on Programming Languages*, vol. 5, OOPSLA, 2021 — **comité de lecture**. <https://doi.org/10.1145/3485510>